Python 数据分析基础篇 2

Pandas 图解

第1章 Pandas 简介

1.1 学习 Pandas 前置知识点

1、Python 基础语言

2、重点 Python 内置数据结构：列表（list）、字符串（str）、元组（tuple）、集合（set）和字典（dict）。

3、序列的索引和切片操作。

4、列表推导式、集合推导式、字典推导式

5、lambda 表达式

6、Python 三个函数式编程基础的函数：filter()、map()和 reduce()。

7、NumPy 库

1.2 pandas 是什么?

pandas 是一个开源的 Python 数据分析库。

1、pandas 基于 NumPy 库，整合 NumPy、SciPy（科学计算）和 Matplotlib（绘图库）功能。

2、pandas 官网：http://pandas.pydata.org/

3、pandas 源代码：https://github.com/pandas-dev/pandas

4、pandas 一词源自“Python and data analysis”和“panel data”字

母缩略写。

5、pandas 广泛应用学术和商业领域，包括金融，经济学，统计学，广告，网络分析等。

1.3 为什么选择 pandas

1、Python 写出易读、整洁并且缺陷最少的代码。

2、使用 pandas 可以完成数据处理和分析中的五个典型步骤：数据加载、数据准备、数据操作、数据建模和数据分析。

3、pandas 提供了快速高效的 Series 和 DataFrame 数据结构。

4、pandas 数据结构基于 NumPy 数组，而 NumPy 底层是用 C 语言实现速度快。

5、可以加载到来自不同文件格式的数据到内存中。

6、可以处理数据对齐和缺失数据。

7、支持基于标签（索引）下标和切片操作，可以处理大数据集。

8、按数据分组以进行聚合和转换。

9、高性能的数据合并和连接。

10、支持时间序列功能。

1.4 课后练习

1、访问 pandas 官网。

2、使用《pandas 用户指南文档》。

3、使用《pandas API 文档》。

第2章 环境搭建

2.1 环境方案 1：手动安装

Python 要求 Python 3.5 以及以上版本。

2.1.1 使用 pip 安装 pandas 等库

还需要安装的库 numpy、scipy、matplotlib。

在 Windows 命令提示符中使用 pip 安装指令：

```
pip install pandas
```

2.1.2 安装 IPython

IPython 是一个加强版本的 Python 解释器。

在命令提示符或终端中使用 pip 安装 IPython 指令：

```
pip install ipython
```

2.2 环境方案 2：安装 Anaconda

Anaconda 指的是一个开源的 Python 发行版本，其包含了 conda、Python 等 1500 多个科学包。

1、Anaconda 官网：https://www.anaconda.com

2、清华大学开源软件镜像站：

https://mirrors.tuna.tsinghua.edu.cn/help/anaconda/

- Anaconda 安装包：

https://mirrors.tuna.tsinghua.edu.cn/anaconda/archive/

- Miniconda 安装包，只包含了 python 和 conda：

https://mirrors.tuna.tsinghua.edu.cn/anaconda/miniconda/

2.2.1 Windows 安装 Anaconda

https://mirrors.tuna.tsinghua.edu.cn/anaconda/archive/

2.2.2 Linux 安装 Anaconda

https://mirrors.tuna.tsinghua.edu.cn/anaconda/archive/

2.2.3 macOS 安装 Anaconda

https://mirrors.tuna.tsinghua.edu.cn/anaconda/archive/

2.3 开发工具

Python shell、Python IDEL、IPython shell 、IDE 工具（Pycharm、Eclipse Pydev 插件、Visual Studio Code、Spyder）、Jupyter Notebook

2.3.1 IPython shell

1、启动

在命令提示符或终端中使用如下指令：

```
ipython
```

2、获得帮助

通过?或??获取获得帮助，示例如下：

3、用 Tab 键语法补全

示例如下：

4、IPython shell 中的快捷键

表 2-1 IPython shell 中常用的快捷键

快捷键	说明
Ctrl + p（或向上箭头）	获取前一个历史命令
Ctrl + n（或向下箭头）	获取后一个历史命令
Ctrl + r	对历史命令的反向搜索
Ctrl + L	清除终端屏幕的内容
Ctrl + d	退出 IPython 会话

示例如下：

5、IPython shell 魔法命令

表 2-2 IPython shell 常用魔法命令

魔法命令	说明
%run	执行外部代码
%timeit	计算代码运行时间
%magic	获得所有可用魔法命令的列表
?	某个魔法命令帮助

示例如下：

2.3.2 Jupyter Notebook

Jupyter Notebook 是 IPython shell 基于浏览器的图形界面。Jupyter Notebook 不仅可以执行 Python/IPython 语句，还允许用户编写科技文章。

1、安装

- Anaconda 完整安装包括 Jupyter Notebook。
- 手动使用 pip 安装指令：

```
pip install jupyter
```

2、启动

在命令提示符或终端中使用如下指令：

```
jupyter notebook
```

示例如下：

2.3.3 Spyder

Spyder(Scientific Python Development Environment)是一个强大的交互式 Python 语言 IDE 开发环境，支持包括 Windows、Linux 和 macOS 系统。Spyder 还集成了很多流行科学软件包，包括 NumPy，SciPy，Pandas，IPython，QtConsole，Matplotlib，SymPy 等。

Spyder 官网：www.spyder-ide.org

1、安装

- Anaconda 完整安装包括 Spyder。
- 手动使用 pip 安装指令：

```
pip install spyder
```

~~手动使用安装 Spyder 不推荐！！！！~~

2、基本用法

2.4 课后练习

1、如何使用 pip 或 conda 指令查询 pandas 版本 。

2、写一个程序来获取 pandas 版本。

参考答案：

```
import pandas as pd
print(pd.__version__)
```

第3章 Series 数据结构

3.1 Pandas 数据结构概述

两种主要的数据结构：

- 一维数据结构 Series
- 二维数据结构 DataFrame

这些数据结构都是带有索引(标签)的，DataFrame 是由 Series 构成。

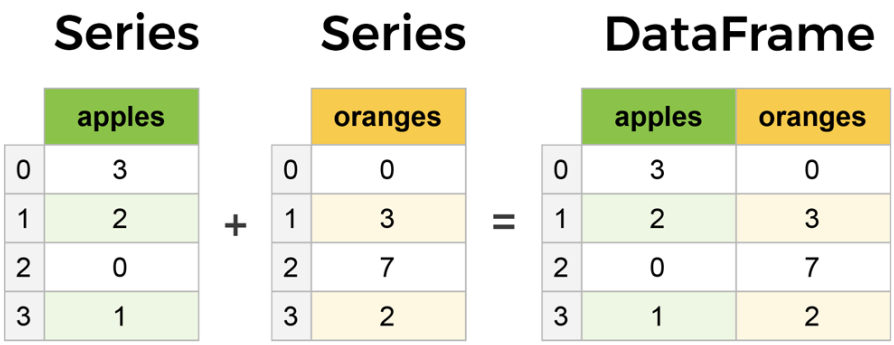

数据结构的操作如下：

插入、删除、修改、查询、分组、连接、合并、汇总

3.2 理解 Series 数据结构

- Series 结构是一种带有标签一维数组对象。
- 能够保存任何数据类型。
- 一个 Series 对象又包含两数组：数据和数据索引（即标签）。
- 数据部分是 numpy 的数组（ndarray）类型。

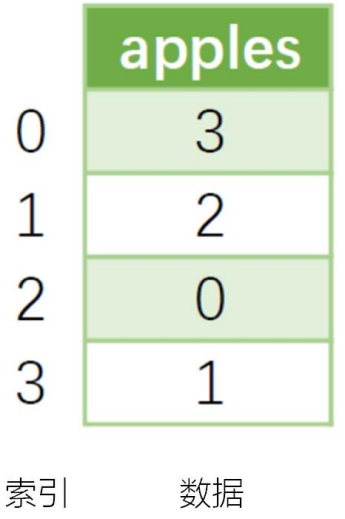

图 3-1 Series 结构

```
In [49]: import pandas as pd

In [50]: apples = pd.Series([3,2,0,1])

In [51]: apples
Out[51]:
0   3
1   2
2   0
3   1
dtype: int64

In [52]: type(apples)
Out[52]: pandas.core.series.Series

In [53]: type(apples.values)
Out[53]: numpy.ndarray

In [54]: type(apples.index)
Out[54]: pandas.core.indexes.range.RangeIndex
```

3.3 创建 Series 对象

Series 构造函数语法格式如下：

```
pandas.Series(data, index, dtype, ...)
```

- data 是 Series 数据部分，可以是列表、NumPy 数组、标量值（常数）、字典。
- index 是 Series 索引（即标签）部分，与数据的长度相同。默认 np.arange(n)。
- dtype 用于数据类型。如果没有则推断数据类型。

1、使用列表创建 Series：

```
In [49]: import pandas as pd
In [50]: apples = pd.Series([3,2,0,1])
In [51]: apples
Out[51]:
0   3
1   2
2   0
3   1
dtype: int64
```

2、使用 NumPy 数组创建 Series：

```
In [49]: import pandas as pd
In [50]: import numpy as np
In [51]: a = np.array([3,2,0,1])
In [52]: apples = pd.Series(a)
In [53]: apples
Out[54]:
0   3
1   2
```

```
2   0
3   1
dtype: int64
```

3、指定索引:

```
In [27]: apples = pd.Series([3,2,0,1], index=['a','b','c','d'])

In [28]: apples
Out[28]:
a   3
b   2
c   0
d   1
dtype: int64
```

4、使用标量创建 Series:

```
In [29]: apples = pd.Series(2, index=['a','b','c','d'])
    ...: apples
Out[29]:
a   2
b   2
c   2
d   2
dtype: int64
```

5、使用字典创建 Series:

```
In [31]: data = {'a' : 3, 'b' : 2, 'c' : 0, 'd' : 1}

In [32]: apples = pd.Series(data)

In [33]: apples
Out[33]:
```

```
a    3
b    2
c    0
d    1
dtype: int64
```

6、指定索引与数据数组长度不同：

```
In [34]: data = {'a' : 3, 'b' : 2, 'c' : 0}

In [35]: apples = pd.Series(data, index=['a','b','c','d'])

In [36]: apples
Out[36]:
a    3.0
b    2.0
c    0.0
d    NaN
dtype: float64
```

提示　指定索引与数据数组长度不同时，按照索引长度创建，不足的数据部分用NaN补齐。

3.4 访问 Series 数据

3.4.1 Series 标签与位置区别

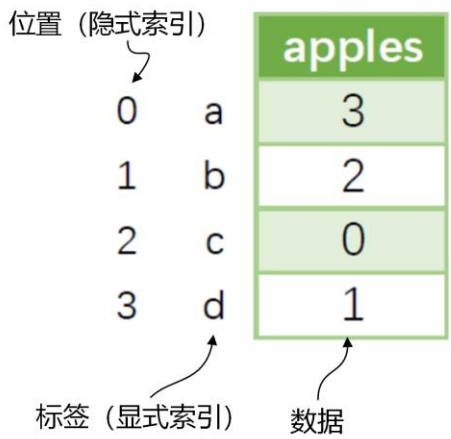

图 3-2 标签和位置

3.4.2 通过下标访问 Series 数据

1、通过标签下标访问数据：

```
In [43]: data = {'a' : 3, 'b' : 2, 'c' : 0, 'd' : 1}
    ...: apples = pd.Series(data)
    ...: # 通过标签下标访问数据
    ...: apples['a']
    ...:
Out[43]: 3
```

2、通过位置下标访问数据：

```
In [41]: apples[0]
Out[41]: 3
```

3.4.3 通过切片访问 Series 数据

1、通过标签切片访问数据：

```
In [60]: apples['a':'c']
Out[60]:
a    3
b    2
c    0
dtype: int64

In [61]: apples['a':'d']
Out[61]:
a    3
b    2
c    0
d    1
dtype: int64

In [62]: apples[:'d']
Out[62]:
a    3
b    2
c    0
d    1
```

提示　标签切片包括结束标签数据。

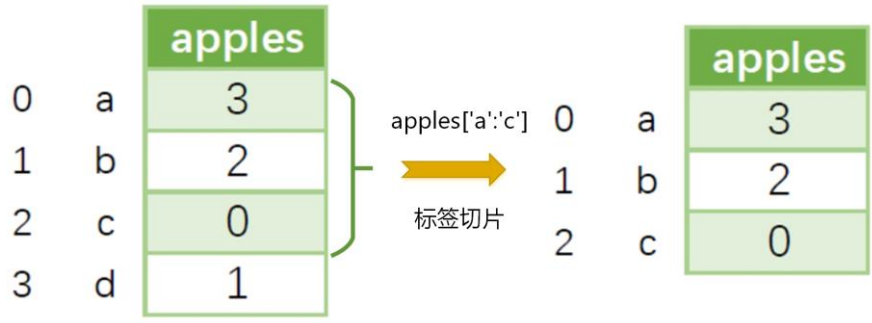

图 3-3 标签切片

2、通过位置切片访问数据：

```
In [63]: apples[:3]
Out[63]:
a    3
b    2
c    0
dtype: int64

In [66]: apples[0:3]
Out[66]:
a    3
b    2
c    0
dtype: int64
```

提示　位置切片不包括结束位置数据。

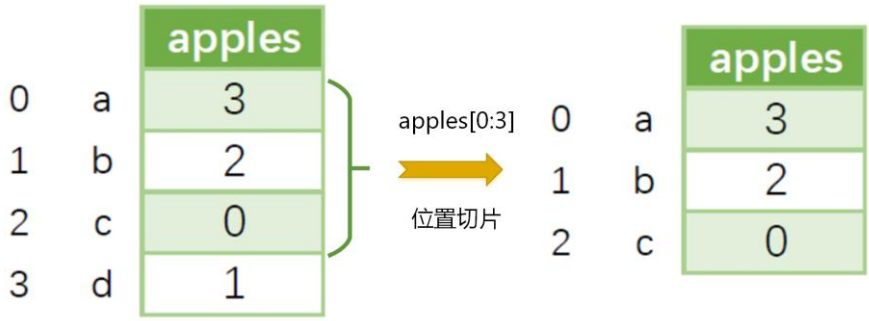

图 3-4 位置切片

3.4.4 通过布尔数组访问 Series 数据

使用布尔数组（或列表）可以访问 Series 数据。

```
In [71]: b = [True, False, True, False]

In [72]: apples[b]
Out[72]:
a    3
c    0
dtype: int64

In [73]: apples[[True, False, True, False]]
Out[73]:
a    3
c    0
dtype: int64

In [74]: apples[ apples >=2 ]
Out[74]:
a    3
b    2
dtype: int64
```

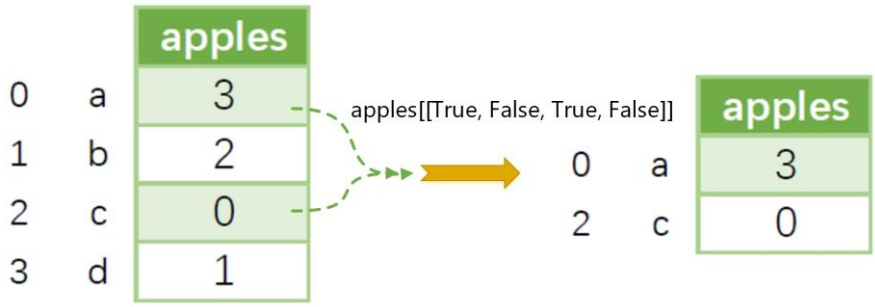

图 3-5 布尔下标访问

注意　不能是apples[True, False, True, False]

3.4.5 通过花式下标访问 Series 数据

使用标签数组（或列表）或位置数组（或列表），作为下标，这称为“花式下标”。

1、标签数组（或列表）“花式下标”

```
In [79]: apples[['b','d']]
Out[79]:
b    2
d    1
dtype: int64
```

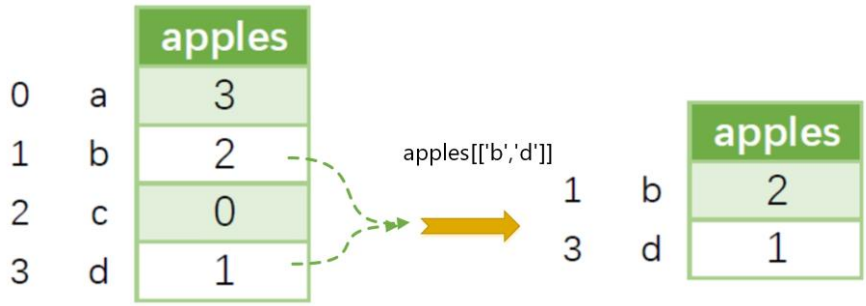

图 3-6 标签花式下标访问

注意　不能是apples['b','d']

2、位置数组（或列表）“花式下标”

```
In [80]: apples[[1,3]]
Out[80]:
b    2
d    1
dtype: int64
```

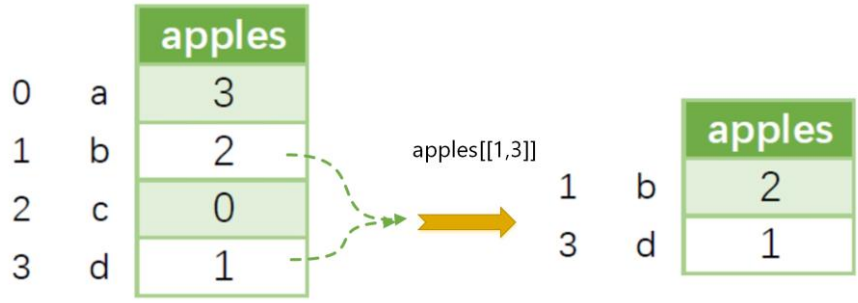

图 3-7 位置花式下标访问

注意　不能是apples[1,3]

3.5 课后练习

1、如何从列表、NumPy 数组和字典创建一个 Series？

参考答案：

```
import pandas as pd
import numpy as np
mylist = list('abcedfghijklmnopqrstuvwxyz')
myarr = np.arange(26)
mydict = dict(zip(mylist, myarr))
ser = pd.Series(mydict)
```

2、编写一个 pandas 程序，根据给定条件获得 Series 子集。

参考答案：

```
import pandas as pd
s = pd.Series([0, 1,2,3,4,5,6,7,8,9,10])
print("原始数据：")
print(s)
print("获得子集：")
new_s = s[s < 6]
print(new_s)
```

3、编写一个 pandas 程序，将 NumPy 数组转换为 Series 对象。

参考答案：

```
import numpy as np
import pandas as pd
np_array = np.array([10, 20, 30, 40, 50])
print("NumPy array:")
```

```
print(np_array)
new_series = pd.Series(np_array)
print("转换后的Series对象：")
print(new_series)
```

4、编写一个 pandas 程序将字典转换为 Series 对象。

参考答案：

```
import pandas as pd
d1 = {'a': 100, 'b': 200, 'c':300, 'd':400, 'e':800}
print("原始数据：")
print(d1)
new series = pd.Series(d1)
print("转换后的Series对象：")
print(new_series)
```

第4章 DataFrame 数据结构

4.1 理解 DataFrame 数据结构

- 由多个 Series 结构构成二维表格对象。
- 每一个列可以不同数据类型。
- 行和列是带有标签的轴。
- 行和列可变的。

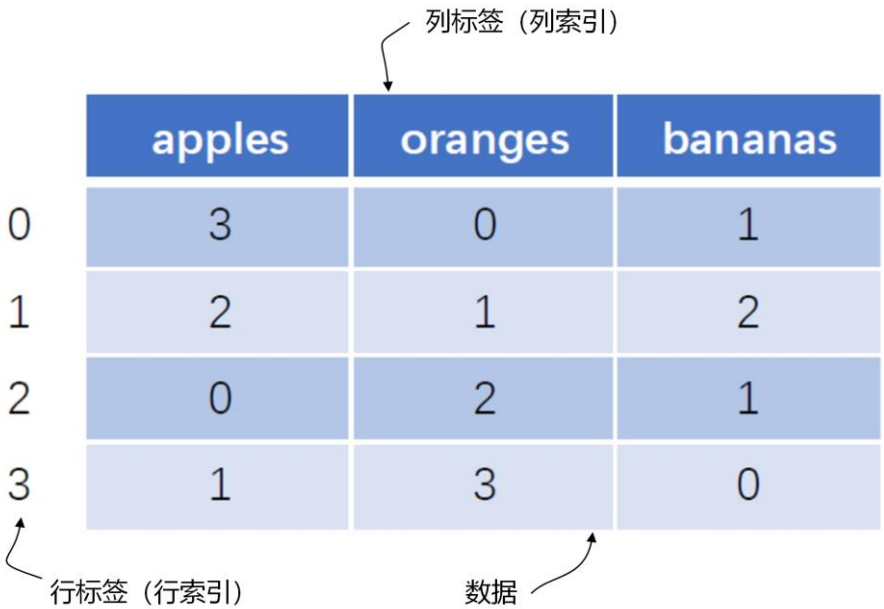

图 4-1 DataFrame 数据结构

4.2 创建 DataFrame 对象

DataFrame 构造函数语法格式如下：

```
pandas.DataFrame( data, index, columns, dtype, ...)
```

- data 是 DataFrame 数据部分，可以是列表、NumPy 数组、字典、Series 对象和其他的 DataFrame 对象。
- index 是行索引（即行标签），默认 np.arange(n)。
- columns 是列索引（即列标签），默认 np.arange(n)。
- dtype 用于数据类型。如果没有则推断数据类型。

1、使用列表创建 DataFrame：

```
In [10]: L =[[3,0,1], [2,1,2],  [0,2,1], [1,3,0]]

In [11]: df = pd.DataFrame(L)

In [12]: df
Out[12]:
   0  1  2
0  3  0  1
1  2  1  2
2  0  2  1
3  1  3  0
```

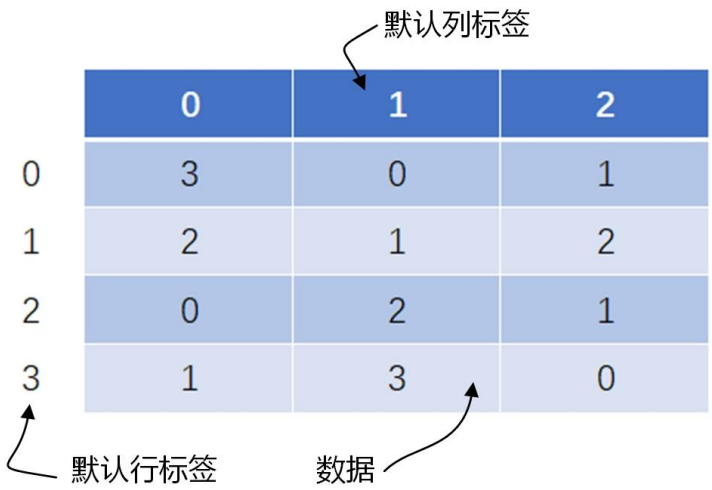

图 4-2 默认行标签和列标签

2、指定行标签和列标签：

```
In [8]: L =[[3,0,1],
     ...:     [2,1,2],
     ...:     [0,2,1],
     ...:     [1,3,0]]

In [9]: df = pd.DataFrame(L,columns=['apples','oranges','bananas'])

In [10]: df
Out[10]:
   apples  oranges  bananas
0       3        0        1
1       2        1        2
2       0        2        1
3       1        3        0

In [11]: df = pd.DataFrame(L,
     ...:                  columns=['apples','oranges','bananas'],
     ...:                  index=['June','Robert','Lily','David'])

In [12]: df
Out[12]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0
```

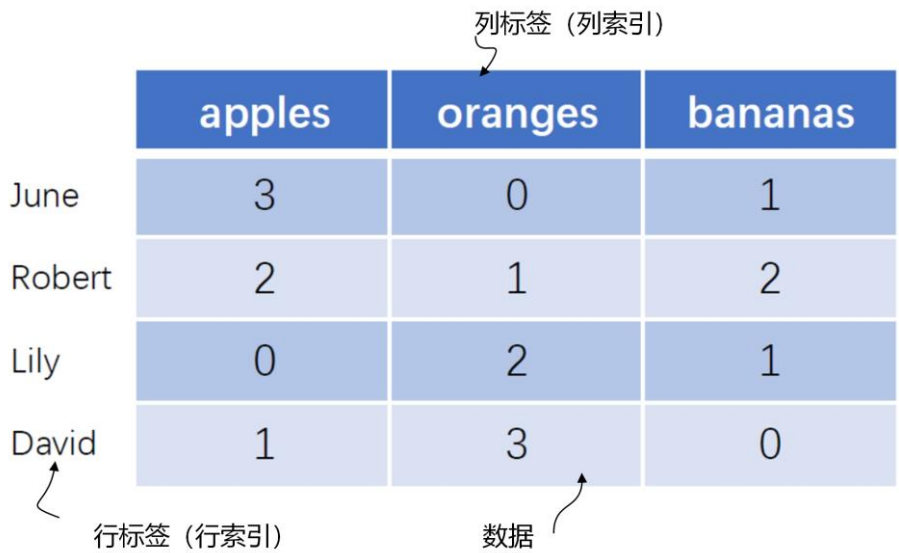

图 4-3 指定行标签和列标签

3、使用字典创建 DataFrame：

```
In [11]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }

In [12]: df = pd.DataFrame(data)

In [13]: df
Out[13]:
   apples  oranges  bananas
0       3        0        1
1       2        1        2
2       0        2        1
3       1        3        0

In [14]: df = pd.DataFrame(data,
    index=['June','Robert','Lily','David'])

In [15]: df
```

```
Out[15]:
       apples  oranges  bananas
June        3        0        1
Robert      2        1        2
Lily        0        2        1
David       1        3        0
```

4、使用列表嵌套字典创建 DataFrame：

```
In [13]: data = [ {'apples': 3, 'oranges': 0, 'bananas': 1},
     ...:         {'apples': 2, 'oranges': 1, 'bananas': 2},
     ...:         {'apples': 0, 'oranges': 2, 'bananas': 1},
     ...:         {'apples': 1, 'oranges': 3, 'bananas': 0} ]
     ...:

In [14]: df = pd.DataFrame(data)

In [15]: df
Out[15]:
   apples  bananas  oranges
0       3        1        0
1       2        2        1
2       0        1        2
3       1        0        3

In [16]: df = pd.DataFrame(data,
    index=['June','Robert','Lily','David'])

In [17]: df
Out[17]:
       apples  bananas  oranges
June        3        1        0
Robert      2        2        1
Lily        0        1        2
David       1        0        3
```

5、使用字典嵌套 Series 创建 DataFrame：

```
In [10]: data = {
    ...:     'apples': pd.Series([3, 2, 0, 1]),
    ...:     'oranges': pd.Series([0, 1, 2, 3]),
    ...:     'bananas': pd.Series([1, 2, 1, 0])
    ...: }
    ...:

In [11]: df = pd.DataFrame(data)

In [12]: df
Out[12]:
   apples  oranges  bananas
0       3        0        1
1       2        1        2
2       0        2        1
3       1        3        0

In [13]: data = {
   'apples': pd.Series([3, 2, 0, 1], index=['June','Robert','Lily','David']),
   'oranges': pd.Series([0, 1, 2, 3], index=['June','Robert','Lily','David']),
   'bananas': pd.Series([1, 2, 1, 0], index=['June','Robert','Lily','David'])
}
In [14]: df = pd.DataFrame(data)

In [15]: df
Out[15]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0
```

4.3 DataFrame 标签与位置区别

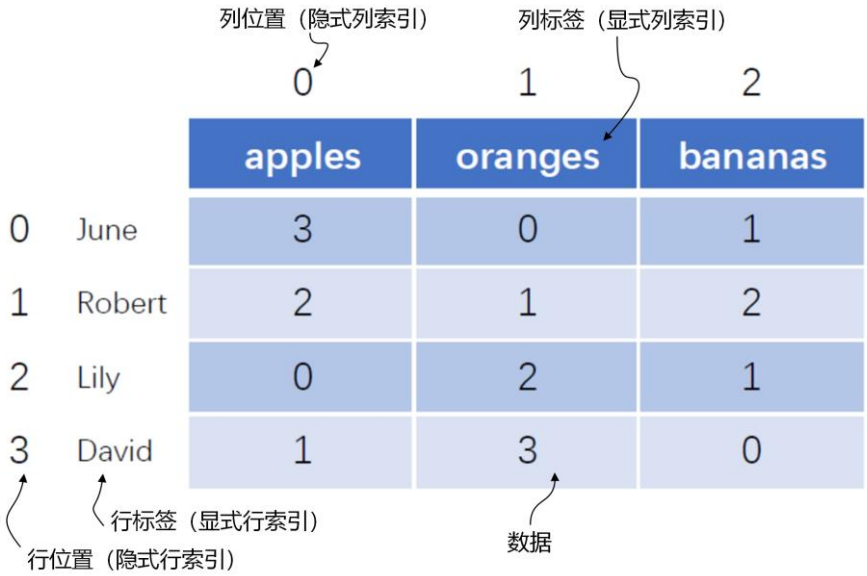

图 4-4 标签和位置

4.4 访问 DataFrame 列

使用[]运算符访问 DataFrame 列，有两种主要形式：

- 单个标签下标，返回表示某列的 Series 对象。
- 多个标签列表（或数组）下标，返回包含多列的 DataFrame 对象。

提示　访问列是不能使用位置下标，只能使用标签下标。

4.4.1 单个标签下标访问 DataFrame 列

1、使用默认列标签：

```
In [30]: L =[[3,0,1],
    ...:     [2,1,2],
    ...:     [0,2,1],
    ...:     [1,3,0]]
    ...: df = pd.DataFrame(L)
    ...: df
Out[30]:
   0  1  2
0  3  0  1
1  2  1  2
2  0  2  1
3  1  3  0

In [31]: df[0]
Out[31]:
0    3
1    2
2    0
3    1
Name: 0, dtype: int64

In [32]: type(df[0])
Out[32]: pandas.core.series.Series
```

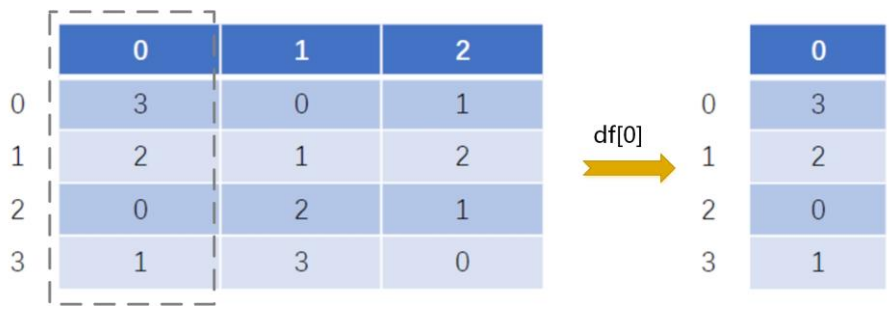

图 4-5 默认列标签

2、使用指定列标签：

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df
Out[33]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0

In [34]: df['apples']
Out[34]:
June      3
Robert    2
Lily      0
David     1
Name: apples, dtype: int64
```

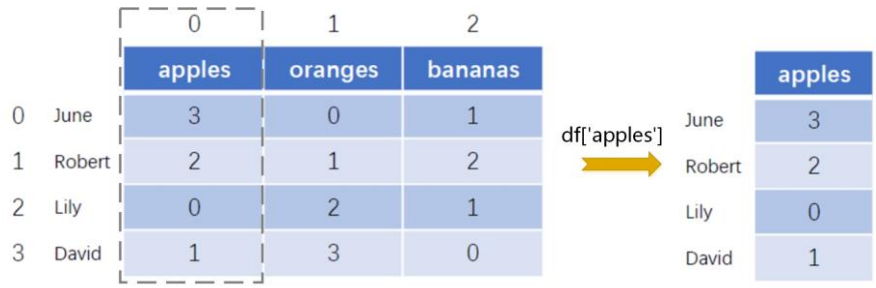

图 4-6 指定列标签

4.4.2 多个标签下标访问 DataFrame 列

1、使用默认列标签：

```
In [30]: L =[[3,0,1],
    ...:     [2,1,2],
    ...:     [0,2,1],
    ...:     [1,3,0]]
    ...: df = pd.DataFrame(L)
    ...: df
Out[30]:
   0  1  2
0  3  0  1
1  2  1  2
2  0  2  1
3  1  3  0

In [31]: df[[0,2]]
Out[31]:
   0  2
0  3  1
1  2  2
2  0  1
3  1  0

In [32]: type(df[[0,2]])
Out[32]: pandas.core.frame.DataFrame
```

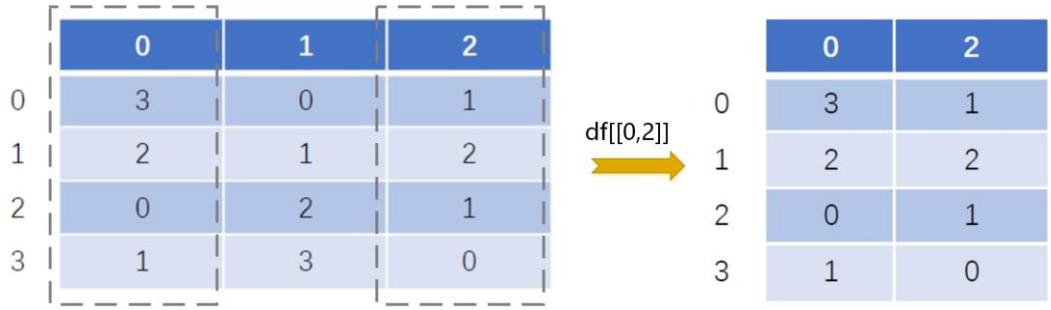

图 4-7 默认列标签

2、使用指定列标签：

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df
Out[33]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0

In [39]: df[['apples', 'bananas']]
Out[39]:
        apples  bananas
June         3        1
Robert       2        2
Lily         0        1
David        1        0
```

		0	1	2
		apples	oranges	bananas
0	June	3	0	1
1	Robert	2	1	2
2	Lily	0	2	1
3	David	1	3	0

	apples	bananas
June	3	1
Robert	2	2
Lily	0	1
David	1	0

图 4-8 指定列标签

4.5 访问 DataFrame 行

访问 DataFrame 行也可以使用[]运算符访问，有两种主要形式：

- 切片
- 布尔数组

4.5.1 通过切片访问 DataFrame 行

1、使用行位置切片：

```
In [30]: L =[[3,0,1],
    ...:     [2,1,2],
    ...:     [0,2,1],
    ...:     [1,3,0]]
    ...: df = pd.DataFrame(L)
    ...: df
Out[30]:
   0  1  2
0  3  0  1
1  2  1  2
2  0  2  1
```

```
3  1  3  0

In [31]: df[0:3]
Out[31]:
   0  1  2
0  3  0  1
1  2  1  2
2  0  2  1

In [32]: df[:3]
Out[32]:
   0  1  2
0  3  0  1
1  2  1  2
2  0  2  1
```

提示　行位置切片不包括结束行数据。

图 4-9 行位置切片

2、使用行标签切片：

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
```

```
    index=['June','Robert','Lily','David'])
   ...: df
Out[33]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0

In [34]: df['June':'David']
Out[34]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0

In [35]: df[0:3]
Out[35]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
```

提示　行标签切片包括结束行数据。

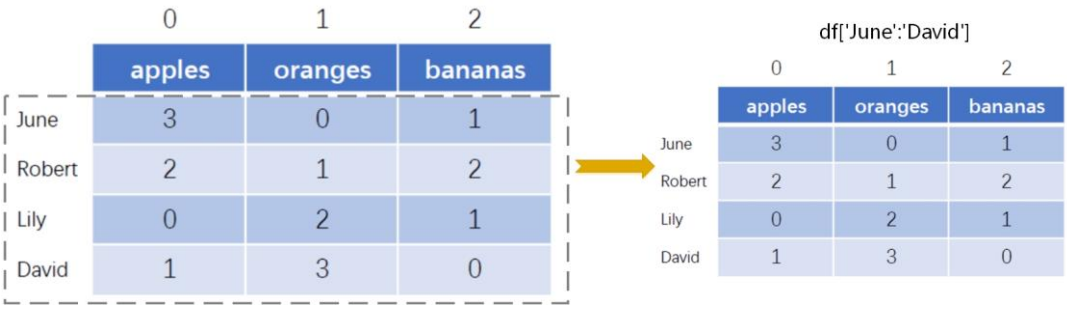

图 4-10 行标签切片

4.5.2 通过布尔数组访问 DataFrame 行

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df
Out[33]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0

In [34]: df[[True, False, True, False]]
Out[34]:
      apples  oranges  bananas
June       3        0        1
Lily       0        2        1

In [35]: b = [True, False, True, False]

In [36]: df[b]
Out[36]:
      apples  oranges  bananas
June       3        0        1
Lily       0        2        1
```

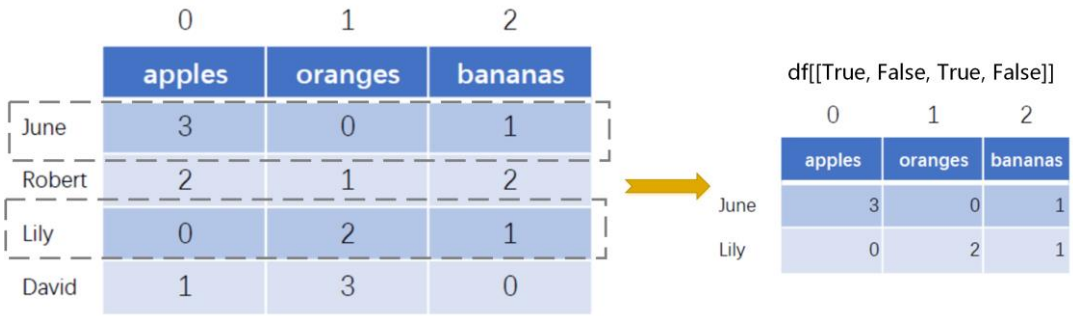

图 4-11 布尔数组访问

4.5.3 通过 query 方法访问 DataFrame 行

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df


In [34]: df.query("apples > 1")
Out[34]:
       apples  oranges  bananas
June        3        0        1
Robert      2        1        2

In [35]: df.query("apples > 1 and bananas <= 2")
Out[35]:
       apples  oranges  bananas
June        3        0        1
Robert      2        1        2

In [36]: df.query("apples > 1 or bananas < 1")
Out[36]:
       apples  oranges  bananas
```

```
June        3       0       1
Robert      2       1       2
David       1       3       0
```

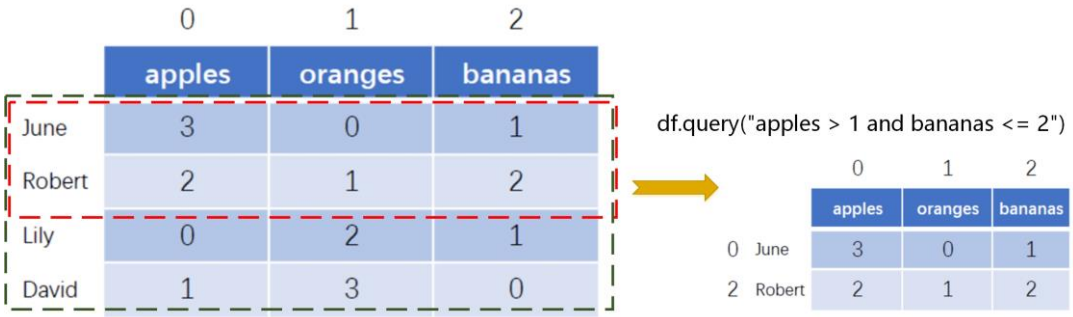

图 4-12 query 方法访问

4.5.4 通过 head 和 tail 方法访问 DataFrame 行

- head(n)方法，返回前 n 行，省略 n 返回前 5 行。
- tail(n)方法，返回后 n 行，省略 n 返回后 5 行。

```
In [33]: df = pd.read_csv("planets.csv")
In [4]: df.head()
Out[4]:
           method  number  orbital_period   mass  distance  year
0  Radial Velocity       1         269.300   7.10     77.40  2006
1  Radial Velocity       1         874.774   2.21     56.95  2008
2  Radial Velocity       1         763.000   2.60     19.84  2011
3  Radial Velocity       1         326.030  19.40    110.62  2007
4  Radial Velocity       1         516.220  10.50    119.47  2009

In [5]: df.tail()
Out[5]:
      method  number  orbital_period  mass  distance  year
```

```
1030  Transit       1       3.941507   NaN    172.0  2006
1031  Transit       1       2.615864   NaN    148.0  2007
1032  Transit       1       3.191524   NaN    174.0  2007
1033  Transit       1       4.125083   NaN    293.0  2008
1034  Transit       1       4.187757   NaN    260.0  2008

In [6]: df.head(1)
Out[6]:
           method  number  orbital_period  mass  distance  year
0  Radial Velocity       1          269.3   7.1      77.4  2006

In [7]: df.tail(2)
Out[7]:
      method  number  orbital_period  mass  distance  year
1033  Transit       1       4.125083   NaN    293.0  2008
1034  Transit       1       4.187757   NaN    260.0  2008
```

4.6 使用 DataFrame 存取器

4.6.1 使用 DataFrame 存取器 loc[]

DataFrame 提供了存取器 loc[]，语法如下：

```
DataFrame.loc[n, m]
```

- n 可以是单个行标签、多行标签数组（或列表）、行标签切片、布尔数组。
- m 可以是单个列标签、多列标签数组（或列表）、列标签切片、布尔数组。

```
In [33]: data = {
   ...:     'apples': [3, 2, 0, 1],
```

```
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df


In [81]: df.loc['David', 'apples']
Out[81]: 1


In [82]: df.loc[['David','Robert'], 'apples']
Out[82]:
David    1
Robert   2
Name: apples, dtype: int64


In [84]: b = [True, False, True, False]


In [85]: df.loc[b, 'apples']
Out[85]:
June   3
Lily   0
Name: apples, dtype: int64


In [86]: df.loc[b, 'apples':]
Out[86]:
      apples  oranges  bananas
June       3        0        1
Lily       0        2        1
```

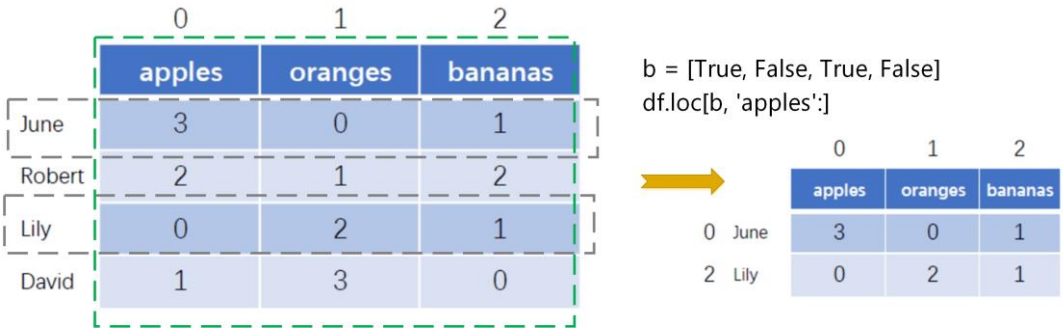

图 4-13 使用 DataFrame 存取器 loc[]

4.6.2 使用 DataFrame 存取器 iloc[]

iloc[]用法与 loc[]类似，区别只是 iloc 其中的参数都是位置，语法如下：

```
DataFrame.iloc[n, m]
```

- n 可以是单个行位置、多行位置数组（或列表）、行位置切片、布尔数组。
- m 可以是单个列位置、多列位置数组（或列表）、列位置切片、布尔数组。

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df


In [90]: df.iloc[3, 0]
Out[90]: 1
```

```
In [91]: df.iloc[[3, 1], 0]
Out[91]:
David    1
Robert   2
Name: apples, dtype: int64

In [92]: b = [True, False, True, False]

In [93]: df.iloc[b, 0]
Out[93]:
June   3
Lily   0
Name: apples, dtype: int64

In [94]: df.iloc[b, 0:]
Out[94]:
     apples  oranges  bananas
June      3        0        1
Lily      0        2        1

In [95]: df.iloc[:, 0:2]
Out[95]:
       apples  oranges
June        3        0
Robert      2        1
Lily        0        2
David       1        3

In [96]: df.iloc[1:3, 0:2]
Out[96]:
       apples  oranges
Robert      2        1
Lily        0        2
```

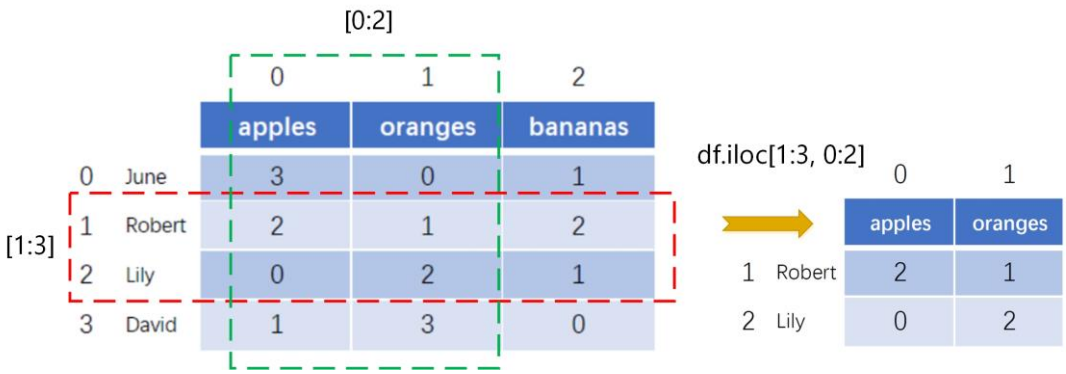

图 4-14 使用 DataFrame 存取器 iloc[]

4.6.3 使用 DataFrame 存取器 at[]和 iat[]

存取器 at[]和 iat[]可以访问 DataFrame 对象中的单个值。他们的语法如下：

```
DataFrame.at[n, m]
```

- n 是行标签。
- m 是列标签。

```
DataFrame.iat[idx_n, idx_m]
```

- idx_n 是行位置。
- idx_m 是列位置。

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
```

```
    index=['June','Robert','Lily','David'])

In [108]: df.at['Robert', 'apples']
Out[108]: 2

In [110]: df.iat[1, 0]
Out[110]: 2
```

4.7 DataFrame 行添加和删除

4.7.1 DataFrame 行添加

行添加使用 append 方法

```
In [22]: data = {
   ...:     'apples': [3, 2, 0, 1],
   ...:     'oranges': [0, 1, 2, 3],
   ...:     'bananas': [1, 2, 1, 0]
   : }
   ...: df = pd.DataFrame(data,
    index=['June','Robert','Lily','David'])
   ...: df
Out[22]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0


In [23]: L =[[1,3,1],
   ...:     [2,4,1]]
   ...:
   ...: df2 = pd.DataFrame(L,
```

```
    ...:  columns=['apples','oranges','bananas'],
     index=['Robert','Tom'])
    ...:

In [24]: df2
Out[24]:
       apples  oranges  bananas
Robert       1        3        1
Tom          2        4        1

In [25]: df3 = df.append(df2)

In [26]: df3
Out[26]:
       apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0
Robert       1        3        1
Tom          2        4        1
```

4.7.2 DataFrame 行删除

行删除 drop(labels=None)

```
In [69]: df4 = df3.drop('Robert')

In [70]: df4
Out[70]:
      apples  oranges  bananas
June       3        0        1
Lily       0        2        1
```

```
David       1       3       0
Tom         2       4       1
```

4.8 DataFrame 列添加和删除

4.8.1 DataFrame 列添加

```
In [71]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df
Out[71]:
        apples  oranges
June         3        0
Robert       2        1
Lily         0        2
David        1        3


In [72]: df['banbanas'] = pd.Series([1, 2, 1, 0],
     index=['June','Robert','Lily','David'])


In [73]: df
Out[73]:
        apples  oranges  banbanas
June         3        0         1
Robert       2        1         2
Lily         0        2         1
David        1        3         0
```

4.8.2 DataFrame 列删除

删除可以使用：

- del 语句
- pop 方法，pop 方法删除选择列并返回删除的列

```
In [74]: del df['banbanas']

In [75]: df
Out[75]:
        apples  oranges
June         3        0
Robert       2        1
Lily         0        2
David        1        3

In [76]: df.pop('apples')
Out[76]:
June      3
Robert    2
Lily      0
David     1
Name: apples, dtype: int64

In [77]: df
Out[77]:
        oranges
June          0
Robert        1
Lily          2
David         3
```

4.9 更改列标题

使用 rename 方法

```
In [78]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df
Out[78]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0


In [79]: df = df.rename(columns={'apples':'苹果','oranges': '桔子
    ','bananas': '香蕉'})


In [80]: df
Out[80]:
        苹果  桔子  香蕉
June     3   0   1
Robert   2   1   2
Lily     0   2   1
David    1   3   0
```

4.10 课后练习

1、编写一个 pandas 程序，将 DataFrame 的第一列转换为 Series。

参考答案：

```
import pandas as pd
d = {'col1': [1, 2, 3, 4, 7, 11], 'col2': [4, 5, 6, 9, 5, 0],
'col3': [7, 5, 8, 12, 1,11]}
df = pd.DataFrame(data=d)
print("原始数据：")
print(df)
print("获得df第col1列的Series对象：")
s1 = df['col1']
print(s1)
print(type(s1))
```

2、编写 pandas 程序，指定字典创建 DataFrame 对象，并具有指定行标签。

参考答案：

```
import pandas as pd


exam_data  = {'name': ['Anastasia', 'Dima', 'Katherine', 'James',
'Emily', 'Michael', 'Matthew', 'Laura', 'Kevin', 'Jonas'],
        'score': [12.5, 9, 16.5, np.nan, 9, 20, 14.5, np.nan, 8, 19],
        'attempts': [1, 3, 2, 3, 2, 3, 1, 1, 2, 1],
        'qualify': ['yes', 'no', 'yes', 'no', 'no', 'yes', 'yes',
'no', 'no', 'yes']}
labels = ['a', 'b', 'c', 'd', 'e', 'f', 'g', 'h', 'i', 'j']


df = pd.DataFrame(exam_data , index=labels)
print(df)
```

3、在第 2 题基础上获得 DataFrame 对象的前 3 行。

参考答案：

```
print(df.iloc[:3])
或
print(df.head(3))
```

4、在第 2 题基础上从 DataFrame 对象中选中两列。

参考答案:

```
print(df[['name', 'score']])
```

5、在第 2 题基础上从 DataFrame 对象中选中 name 和 score 两列的 1、3、5、6 行数据。

参考答案:

```
print(df.iloc[[1, 3, 5, 6], [1, 3]])
```

6、在第 2 题基础上从 DataFrame 对象中选择分数在 15 到 20 之间（包括 15 和 20）的行。

参考答案:

```
print(df.query("score>=15 and score<=20"))
或
print(df[df['score'].between(15, 20)])
```

7、在第 2 题基础上从 DataFrame 对象中插入新列。

参考答案:

```
color =
['Red','Blue','Orange','Red','White','White','Blue','Green','Green',
'Red']
df['color'] = color
print(df)
```

8、在第 2 题基础上从 DataFrame 对象中删除一列。

参考答案：

```
df.pop('attempts')
print(df)
```

9、编写一个 pandas 程序来重新给定 DataFrame 对象的列。

参考答案：

```
import pandas as pd
d = {'col1': [1, 2, 3], 'col2': [4, 5, 6], 'col3': [7, 8, 9]}
df = pd.DataFrame(data=d)
print("原始DataFrame对象：")
print(df)
df.columns = ['Column1', 'Column2', 'Column3']
df = df.rename(columns={'col1': 'Column1', 'col2': 'Column2',
'col3': 'Column3'})
print("重命名DataFrame列名:")
print(df)
```

10、编写一个 pandas 程序，根据某些列中的值从给定的 DataFrame 对象中选择行。

参考答案：

```
import pandas as pd
d = {'col1': [1, 4, 3, 4, 5], 'col2': [4, 5, 6, 7, 8], 'col3': [7,
8, 9, 0, 1]}
df = pd.DataFrame(data=d)
print("原始DataFrame对象：")
print(df)
print("colum1值的行== 4 :")
print(df.loc[df['col1'] == 4])
```

11、在第 2 题基础上变更 DataFrame 对象列顺序。

参考答案：

```
df = df[['col3', 'col2', 'col1']]
print(df)
```

12、在第 2 题基础上从 DataFrame 对象中选中指定行。

参考答案:

```
print(df.iloc[3])
```

13、在第 2 题基础上从 DataFrame 对象中选择除某列外的其他列。

参考答案:

```
df = df.loc[:, df.columns != 'col3']
print(df)
```

第5章 索引

5.1 Index 对象

5.1.1 一级索引 Index 对象

1、从 Series 对象中获得 Index 对象：

```
In [1]:  data = {'a' : 3, 'b' : 2, 'c' : 0, 'd' : 1}
In [2]: s = pd.Series(data)
In [3]: s
Out[3]:
a    3
b    2
c    0
d    1
dtype: int64


In [4]: s.index
Out[4]: Index(['a', 'b', 'c', 'd'], dtype='object')
```

2、从 DataFrame 对象中获得 Index 对象：

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])


In [34]: df.index
```

```
Out[34]: Index(['June', 'Robert', 'Lily', 'David'], dtype='object')

In [35]: df.columns
Out[35]: Index(['apples', 'oranges', 'bananas'], dtype='object')
```

5.1.2 创建 Index 对象

1、在 Series 对象中使用 Index 对象：

```
In [1]: labels = pd.Index(['a', 'b', 'c', 'd', 'e'])

In [2]: s = pd.Series(np.arange(5), index=labels)

In [3]: s
Out[3]:
a   0
b   1
c   2
d   3
e   4
dtype: int32
```

2、在 DataFrame 对象中使用 Index 对象：

```
In [7]: L =[[3,0,1],
    ...:    [2,1,2],
    ...:    [0,2,1],
    ...:    [1,3,0]]
    ...: df = pd.DataFrame(L)
    ...: df
Out[7]:
   0  1  2
0  3  0  1
```

```
1  2  1  2
2  0  2  1
3  1  3  0

In [8]: row_labels = pd.Index(['June', 'Robert', 'Lily', 'David'])
In [9]: col_labels = pd.Index(['apples', 'oranges', 'bananas'])
In [10]: df = pd.DataFrame(L, index=row_labels, columns=col_labels)

In [11]: df
Out[11]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0
```

5.1.3 重建索引

重建索引使用 reindex()方法。

1、在 Series 对象中重建索引:

```
In [1]: import pandas as pd
   ...: import numpy as np

In [2]: labels = pd.Index(['a', 'b', 'c', 'd', 'e'])
   ...: s = pd.Series(np.arange(5), index=labels)
   ...: s
Out[2]:
a    0
b    1
c    2
d    3
e    4
```

```
dtype: int32

In [3]: s1 = s.reindex(['a', 'b', 'c'])
   ...: s1
Out[3]:
a    0
b    1
c    2
dtype: int32

In [4]: s2 = s.reindex(['a', 'b', 'c', 'd', 'e' ,'f'])
   ...: s2
Out[4]:
a    0.0
b    1.0
c    2.0
d    3.0
e    4.0
f    NaN
dtype: float64
```

2、在 DataFrame 对象中重建索引:

```
In [6]: L =[[3,0,1],
   ...:     [2,1,2],
   ...:     [0,2,1],
   ...:     [1,3,0]]
   ...: df = pd.DataFrame(L,
   ...:                   columns=['apples','oranges','bananas'],
   ...:                   index=['June','Robert','Lily','David'])

In [7]: df2 = df.reindex(['June', 'Lily', 'Robert'])
   ...: df2
Out[7]:
       apples  oranges  bananas
```

```
June        3       0       1
Lily        0       2       1
Robert      2       1       2

In [8]: df3 = df.reindex(columns=['apples', 'bananas', 'oranges'])
   ...: df3
Out[8]:
        apples  bananas  oranges
June         3        1        0
Robert       2        2        1
Lily         0        1        2
David        1        0        3
```

5.2 MultiIndex 对象

5.2.1 创建多级索引对象

一维 Series 对象表示二维数据：

单级索引的DataFrame对象

	apples	oranges	bananas
June	3	0	1
Robert	2	1	2
Lily	0	2	1
David	1	3	0

多级索引的Series对象

names	fruits	
June	apples	3
	oranges	0
	bananas	1
Robert	apples	2
	oranges	1
	bananas	2
Lily	apples	0
	oranges	2
	bananas	1
David	apples	1
	oranges	3
	bananas	0

图 5-1 多级索引对象

```
In [78]: keys =[('June', 'apples'), ('June', 'oranges'),
    ('June', 'bananas'),

    ...:         ('Robert', 'apples'), ('Robert', 'oranges'),
    ('Robert', 'bananas'),

    ...:         ('Lily', 'apples'), ('Lily', 'oranges'),
    ('Lily', 'bananas'),

    ...:         ('David', 'apples'), ('David', 'oranges'),
    ('David', 'bananas') ]


In [81]: index = pd.MultiIndex.from_tuples(keys,
    names=['names', 'fruits'])


In [82]: index

Out[82]:

MultiIndex(levels=[['David', 'June', 'Lily', 'Robert'],
    ['apples', 'bananas', 'oranges']],

          labels=[[1, 1, 1, 3, 3, 3, 2, 2, 2, 0, 0, 0], [0, 2,
    1, 0, 2, 1, 0, 2, 1, 0, 2, 1]],

          names=['names', 'fruits'])

In [87]: data = [3,0,1,

    ...:        2,1,2,

    ...:        0,2,1,

    ...:        1,3,0]

    ...:


In [89]: s = pd.Series(data, index=index)


In [90]: s

Out[90]:

names   fruits

June    apples     3

       oranges    0

       bananas    1

Robert  apples     2

       oranges    1

       bananas    2

Lily    apples     0

       oranges    2
```

```
        bananas    1
David   apples     1
        oranges    3
        bananas    0
dtype: int64
```

创建 MultiIndex 对象方法：

- pandas.MultiIndex.from_arrays,从数组创建。
- pandas.MultiIndex.from_product，从笛卡尔积创建。
- pandas.MultiIndex.from_tuples，从元组创建。
- pandas.MultiIndex.from_frame，另外 DataFrame 对象创建。

5.2.2 多级索引行列转换

1、多级索引转化普通索引

unstack()方法可以快速将一个多级索引的 Series 转化为普通索引的 DataFrame：

```
In [125]: s.unstack()
Out[125]:
fruits  apples  bananas  oranges
names
David        1        0        3
June         3        1        0
Lily         0        1        2
Robert       2        2        1
```

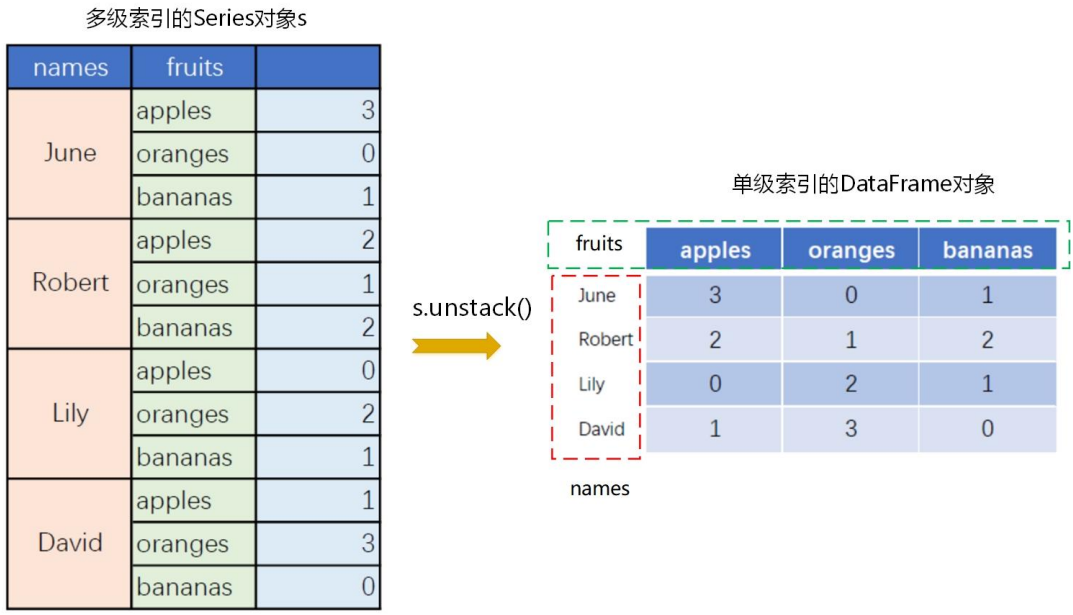

图 5-2 多级索引转化普通索引

2、stack()方法可以将一个普通索引的 DataFrame 转化为多级索引的 Series:

```
In [33]: data = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])


In [34]: df.stack()
Out[34]:
June    apples     3
        oranges    0
        bananas    1
Robert  apples     2
        oranges    1
        bananas    2
Lily    apples     0
        oranges    2
```

```
          bananas    1
  David   apples     1
          oranges    3
          bananas    0
dtype: int64
```

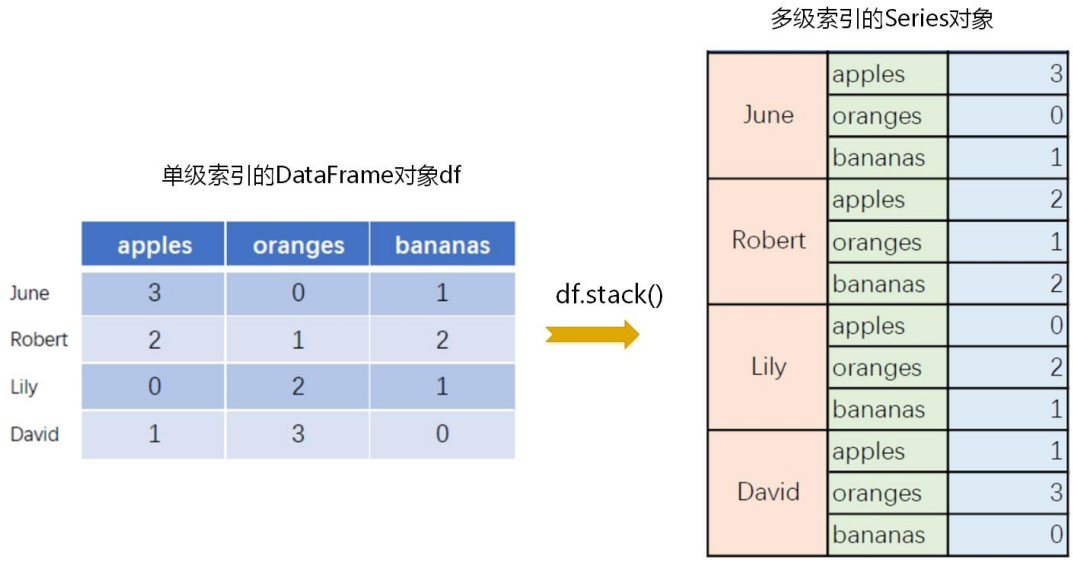

	apples	oranges	bananas
June	3	0	1
Robert	2	1	2
Lily	0	2	1
David	1	3	0

June	apples	3
	oranges	0
	bananas	1
Robert	apples	2
	oranges	1
	bananas	2
Lily	apples	0
	oranges	2
	bananas	1
David	apples	1
	oranges	3
	bananas	0

图 5-3 普通索引转化多级索引

5.2.3 多级索引数据存取

多级索引数据存值可以使用[]运算符，也可以使用 loc 等存取器。语法：

[第 1 级索引的标签（或切片），第 2 级索引的标签（或切片），...，第 n 级索引的标签（或切片）]

loc 存取器还可以使用标签列表。

```
In [15]: s[:,'apples']
Out[15]:
names
June      3
Robert    2
```

```
Lily      0
David     1
dtype: int64

In [16]: s.loc[:,'apples']
Out[16]:
names
June      3
Robert    2
Lily      0
David     1
dtype: int64

In [17]: s['June','apples']
Out[17]: 3

In [18]: s.loc['June','apples']
Out[18]: 3

In [19]: s['June',:]
Out[19]:
fruits
apples     3
oranges    0
bananas    1
dtype: int64

In [20]: s.loc['June',:]
Out[20]:
fruits
apples     3
oranges    0
bananas    1
dtype: int64
```

5.3 课后练习

1、编写一个 pandas 程序来改变 Series 对象索引。

参考答案：

```
import pandas as pd
s = pd.Series(data = [1,2,3,4,5], index = ['A', 'B', 'C','D','E'])
print("原始数据：")
print(s)
s = s.reindex(index = ['B','A','C','D','E'])
print("改变Series对象索引:")
print(s)
```

2、创建多级索引对象，保存城市信息，包括所在国家（country）、面积（area）和人口（population）。

参考答案：

```
import pandas as pd
cities =[('Vienna', 'country'),
       ('Vienna', 'area'),
       ('Vienna', 'population'),

       ('Hamburg', 'country'),
       ('Hamburg', 'area'),
       ('Hamburg', 'population'),

       ('Berlin', 'country'),
       ('Berlin', 'area'),
       ('Berlin', 'population'),

       ('Zürich', 'country'),
       ('Zürich', 'area'),
       ('Zürich', 'population')]
index = pd.MultiIndex.from_tuples(cities)
或者
```

```
index =
pd.MultiIndex.from_product([['Vienna','Hamburg','Berlin','Zürich'],
                                    ['country','area','population']])
```

3、在第 2 题基础上，创建具有多级索引的 Series 对象。

参考答案:

```
data = ["Austria", 414.60,    1805681,
        "Germany", 755.00,    1760433,
        "Germany", 891.85,    3562166,
        "Switzerland", 87.88, 378884]
city_series = pd.Series(data, index=index)
```

4、在第 3 题基础上访问 Series 对象，获取城市数据、城市面积、城市人口。

参考答案:

```
data = ["Austria", 414.60,    1805681,
        "Germany", 755.00,    1760433,
        "Germany", 891.85,    3562166,
        "Switzerland", 87.88, 378884]
city_series = pd.Series(data, index=index)

print('城市数据', city_series['Vienna'])
print("城市面积", city_series["Vienna", "area"])
print("城市人口", city_series["Vienna", "population"])
```

第6章 数据读写操作

数据包括格式：文本格式和二进制格式。

- 文本格式：CSV、HTML、JSON 等。
- 二进制格式：Excel、Pickle、HDF5 等。

6.1 读写 Excel 文件

6.1.1 读取 Excel 文件数据

读取 Excel 文件数据函数是 pandas.read_excel()，该函数返回值是 DataFrame 对象，该函数语法格式：

```
pandas.read_excel(io, sheet_name=0, header=0, index_col=None,
skiprows=None, skipfooter=0)
```

主要的参数如下：

- io：是输入 Excel 文件。可以是字符串、文件对象、ExcelFile 对象，可以是本地文件，也可以是网络 URL。
- sheet_name：是 Excel 文件工作表名，可以是字符串、整数（基于 0 的工作表位置索引）、列表（选择多个工作表）。
- header：用作 DataFrame 对象列标签的行号，默认是 0（第一行）；如果设置 None，则没有指定列标签。
- index_col：用作 DataFrame 对象的行标签的列号，默认是 None。
- skiprows：忽略文件头部行数，默认是 None。
- skipfooter：忽略文件尾部行数，默认是 0。

6.1.2 示例：从 Excel 文件读取全国总人口数据

数据来源国家统计局（http://www.stats.gov.cn/）

读取【全国总人口数据.xls】文件

1、基本参数

```
In [13]: file_path = 'data\\'


In [14]: df10 = pd.read_excel(file_path+'全国总人口10年数据.xls')


In [15]: df10
Out[15]:
                                                数据库：年度数据 Unnamed:
    1     ...     Unnamed: 9 Unnamed: 10
0                                               时间：最近10年
    NaN     ...            NaN         NaN
1                                                       指标      2018年     ...
    2010年       2009年
2                                             年末总人口(万人)
    139538     ...         134091      133450
3                                               男性人口(万人)
    71351     ...          68748       68647
4                                               女性人口(万人)
    68187     ...          65343       64803
5                                               城镇人口(万人)
    83137     ...          66978       64512
6                                               乡村人口(万人)
    56401     ...          67113       68938
7  注：1981年及以前人口数据为户籍统计数；1982、1990、2000、2010年数据为当
    年...         NaN     ...             NaN         NaN
8                                             数据来源：国家统计局
    NaN     ...            NaN         NaN


[9 rows x 11 columns]
```

2、忽略文件头部和尾部的行数

```
In [21]: df10 = pd.read_excel(file_path+'全国总人口数
    据.xls',skiprows=2,skipfooter=2)


In [22]: df10
Out[22]:
         指标    2018年    2017年    2016年    2015年    2014年    2013年
    2012年    2011年    2010年    2009年
0  年末总人口(万人)  139538  139008  138271  137462  136782  136072
    135404  134735  134091  133450
1   男性人口(万人)   71351   71137   70815   70414   70079   69728
    69395   69068   68748   68647
```

```
2   女性人口(万人)   68187   67871   67456   67048   66703   66344
    66009   65667   65343   64803

3   城镇人口(万人)   83137   81347   79298   77116   74916   73111
    71182   69079   66978   64512

4   乡村人口(万人)   56401   57661   58973   60346   61866   62961
64222   65656   67113   68938
```

3、指定行标签

```
In [69]: df10 = pd.read_excel(file_path+'全国总人口数
    据.xls',skiprows=2,skipfooter=2, index_col=0)


In [70]: df10

Out[70]:

          2018年   2017年   2016年   2015年   2014年   2013年   2012年
    2011年   2010年   2009年

指标

年末总人口(万人)  139538  139008  138271  137462  136782  136072
    135404  134735  134091  133450

男性人口(万人)    71351   71137   70815   70414   70079   69728   69395
    69068   68748   68647

女性人口(万人)    68187   67871   67456   67048   66703   66344   66009
    65667   65343   64803

城镇人口(万人)    83137   81347   79298   77116   74916   73111   71182
    69079   66978   64512

乡村人口(万人)    56401   57661   58973   60346   61866   62961   64222
65656   67113   68938
```

4、指定工作表

```
In [71]: df20 = pd.read_excel(file_path+'全国总人口数据.xls',
    sheet_name='20年数据',skiprows=2,skipfooter=

   ...: 2, index_col=0)


In [72]: df20

Out[72]:

     年末总人口(万人)  男性人口(万人)  女性人口(万人)  城镇人口(万人)
    乡村人口(万人)

时间

2018年     139538     71351     68187     83137     56401
```

```
2017年    139008    71137    67871    81347    57661
2016年    138271    70815    67456    79298    58973
2015年    137462    70414    67048    77116    60346
2014年    136782    70079    66703    74916    61866
2013年    136072    69728    66344    73111    62961
2012年    135404    69395    66009    71182    64222
2011年    134735    69068    65667    69079    65656
2010年    134091    68748    65343    66978    67113
2009年    133450    68647    64803    64512    68938
2008年    132802    68357    64445    62403    70399
2007年    132129    68048    64081    60633    71496
2006年    131448    67728    63720    58288    73160
2005年    130756    67375    63381    56212    74544
2004年    129988    66976    63012    54283    75705
2003年    129227    66556    62671    52376    76851
2002年    128453    66115    62338    50212    78241
2001年    127627    65672    61955    48064    79563
2000年    126743    65437    61306    45906    80837
1999年    125786    64692    61094    43748    82038
```

sheet_name='20 年数据'可以替换为 sheet_name=1

6.1.3 写入数据到 Excel 文件

写入数据到 Excel 文件数据是通过 Series 和 DataFrame 对象的 to_excel()方法实现，该方法语法格式：

```
to_excel(excel_writer, sheet_name='Sheet1', header=True, index=True)
```

主要的参数如下：

- excel_writer：是写入 Excel 文件。可以是字符串、ExcelWriter 对象。
- sheet_name：是 Excel 文件工作表名，字符串类型，默认是'Sheet1'。
- header：是写入列名。可以是布尔类型（False 是不写入列名，True 是将 Series 和 DataFrame 对象列标签作为列名）；也可以字符串列表

（自定义列名）。

- index：是否写入行名。该参数只能是布尔类型，默认是 True。

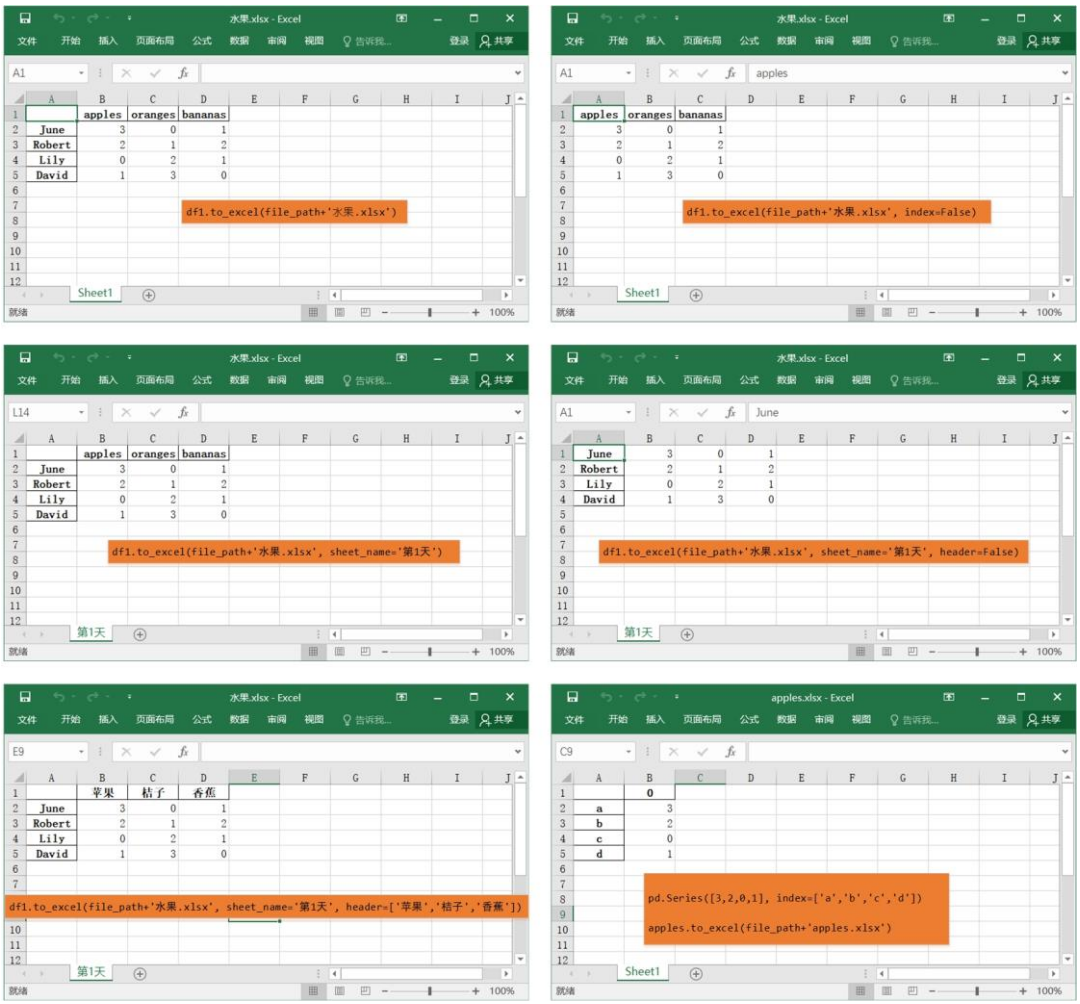

图 6-1 写入 Excel 文件

6.1.4 示例：写入水果数据到 Excel 文件

```
In [13]: file_path = 'data\\'

In [38]: data1 = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
```

```
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df1 = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df1
Out[38]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0


In [39]: df1.to_excel(file_path+'水果.xlsx')
In [40]: df1.to_excel(file_path+'水果.xlsx', index=False)
In [41]: df1.to_excel(file_path+'水果.xlsx', sheet_name='第1天')
In [42]: df1.to_excel(file_path+'水果.xlsx', sheet_name='第1天',
     header=False)
In [43]: df1.to_excel(file_path+'水果.xlsx', sheet_name='第1天',
     header=['苹果','桔子','香蕉'])
In [44]: apples = pd.Series([3,2,0,1], index=['a','b','c','d'])
In [45]: apples.to_excel(file_path+'apples.xlsx')


In [46]: with pd.ExcelWriter(file_path+'水果.xlsx') as writer:
     ...:     df1.to_excel(writer, sheet_name='第1天')
     ...:     apples.to_excel(writer, sheet_name='第2天')
```

6.2 读写 CSV 文件

6.2.1 读取 CSV 文件数据

读取 CSV 文件数据函数是 pandas.read_csv(),该函数返回值是 DataFrame 对象，该函数语法格式:

```
  pandas.read_csv(filepath_or_buffer, sep=', ', delimiter=None,
header='infer', index_col=None, skiprows=None, skipfooter=0)
```

主要的参数如下：

- filepath_or_buffer：是输入 CSV 文件。可以是字符串、文件对象，可以是本地文件，可以是网络 URL。
- sep 或 delimiter：用于分隔每行字段的字符或正则表达式。
- header：用作 DataFrame 对象列标签的行号，默认是'infer'（自动推断）。
- index_col：用作 DataFrame 对象的行标签的列号，默认是 None。
- skiprows：忽略文件头部行数，默认是 None。
- skipfooter：忽略文件尾部行数，默认是 0。
- engine：解析引擎，取值是有 c 和 python，默认是 c。c 不支持 skipfooter 参数。

6.2.2 示例：从 CSV 文件读取全国总人口数据

数据来源国家统计局（http://www.stats.gov.cn/）

1、读取【全国总人口 10 年数据.csv】文件

```
df10 = pd.read_csv(file_path+'全国总人口10年数
    据.csv',skiprows=2,skipfooter=2,engine='python')

df10 = pd.read_csv(file_path+'全国总人口10年数
    据.csv',skiprows=2,skipfooter=2,index_col=0, engine='python')

df10 = pd.read_csv(file_path+'全国总人口10年数
    据.csv',header=2,skipfooter=2,index_col=0, engine='python')

df10
```

2、使用 sep 参数

```
In [4]: df1 = pd.read_csv(file_path+'pandas_tutorial_read.csv',
    sep=';',header=None)

In [5]: df1.head()

Out[5]:

   2018-01-01 00:01:01  read  country_7  2458151261     SEO  North
    America

0  2018-01-01 00:03:20  read  country_7  2458151262     SEO  South
    America
```

```
1  2018-01-01 00:04:01  read  country_7  2458151263  AdWords
    Africa
2  2018-01-01 00:04:02  read  country_7  2458151264  AdWords
    Europe
3  2018-01-01 00:05:03  read  country_8  2458151265   Reddit  North
    America
4  2018-01-01 00:05:42  read  country 6  2458151266   Reddit  North
America
```

6.2.3 写入数据到 CSV 文件

写入数据到 CSV 文件数据是通过 Series 和 DataFrame 对象的 to_csv()方法实现，该方法语法格式：

```
 to_csv(path_or_buf=None, sep=', ', header=True, index=True,
encoding=None)
```

主要的参数如下：

- path_or_buf：是写入 CSV 文件。可以是字符串、文件对象。
- sep：用于分隔每行字段的字符。
- header：是写入列名。可以是布尔类型 (False 是不写入列名，True 是将 Series 和 DataFrame 对象列标签作为列名)；也可以字符串列表（自定义列名）。
- index：是否写入行名。该参数只能是布尔类型，默认是 True。
- encoding：设置字符集，Python2 默认 ascii，Python3 默认 utf-8。

6.2.4 示例：写入水果数据到 CSV 文件

```
In [13]: file_path = 'data\\'


In [38]: data1 = {
    ...:     'apples': [3, 2, 0, 1],
    ...:     'oranges': [0, 1, 2, 3],
    ...:     'bananas': [1, 2, 1, 0]
    ...: }
    ...: df1 = pd.DataFrame(data,
     index=['June','Robert','Lily','David'])
    ...: df1
```

```
Out[38]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0


In [39]: df1.to_csv(file_path+'水果.csv', index=False)
In [40]: df1.to_csv(file_path+'水果.csv', header=False)
In [41]: df1.to_csv(file_path+'水果.csv', header=['苹果','桔子','香蕉
    '])
In [42]: df1.to_csv(file_path+'水果.csv', header=['苹果','桔子','香蕉
    '],encoding='gbk')
In [43]: apples = pd.Series([3,2,0,1], index=['a','b','c','d'])
In [44]: apples.to_csv(file_path+'apples.csv')
```

关于 CSV 字符集问题：

6.3 课后练习

1、读取 CSV 数据（煤矿生成历史数据 2013.csv）到 DataFrame 对象，并将前 20 行跳过。

参考答案：

```
import pandas as pd
df = pd.read_csv(file_dir+'煤矿生成历史数据2013.csv', skiprows = 20,
engine='python')
df
```

2、读取 CSV 数据（煤矿生成历史数据 2013.csv）到 DataFrame 对象，并示最后十行。

参考答案：

```
import pandas as pd
df = pd.read_csv(file_dir+'煤矿生成历史数据2013.csv',engine='python')
df.tail(10)
```

3、读取 CSV 数据（煤矿生成历史数据 2013.csv）到 DataFrame 对象，并查找特定的“矿山 ID”。

参考答案:

```
import pandas as pd
df = pd.read_csv(file_dir+'煤矿生成历史数据2013.csv', engine='python')
df[df["矿山ID"]==102901]
```

4、读取 CSV 数据（煤矿生成历史数据 2013.csv）到 DataFrame 对象，并示并查找“工时”> 20000 的详细信息。

参考答案:

```
import pandas as pd
df = pd.read_csv(file_dir+'煤矿生成历史数据2013.csv',engine='python')
df[df["工时"] > 20000]
```

5、读取 Excel 文件数据（雇员.xlsx）到 DataFrame 对象，并转换数据以使用 hire_date 作为索引。

参考答案:

```
import pandas as pd
df = pd.read_excel(file_dir+'雇员.xlsx', index_col=0)
result = df.set_index(['hire_date'])
print(result)
```

6、读取 Excel 文件数据（雇员.xlsx）到 DataFrame 对象，并根据两个特定月份和年份之间 hire_date 的员工列表。

参考答案：

```
import pandas as pd
df = pd.read_excel(file_dir+'雇员.xlsx', index_col=0)
result = df.query("hire_date >='2005-1' and hire_date < '2006-1'")
或
result = df[(df['hire_date'] >='2005-1') & (df['hire_date'] < '2006-1')]
print(result)
```

7、读取 Excel 文件数据(雇员.xlsx)到 DataFrame 对象，并找 hire_date> 2007-01-01 雇员列表。

参考答案：

```
import pandas as pd
df = pd.read_excel(file_dir+'雇员.xlsx', index_col=0)
df[df['hire_date'] >='20070101']
或
df[df['hire_date'] >='2007-1-1']
或
df.query("hire_date >= '2007-1-1'")
```

第7章 数据操作

7.1 算术运算

对象（Series 和 DataFrame）中的元素可以进行算术（加、减、乘、除等）计算，当索引相同时对象对应元素进行计算；如果索引不同，则返回结果的索引是两个索引的并集。

7.1.1 使用算术运算符

算术运算符包括一元取反（-），二元运算符包括：+、-、*、/、%、**和//。

1、两个 Series 对象算术运算：

```
In [20]: s1 = pd.Series([8, 7, 3], index=list('abc'))

In [21]: s1
Out[21]:
a    8
b    7
c    3
dtype: int64

In [22]: s2 = pd.Series([3, 5, 8], index=list('abc'))

In [23]: s2
Out[23]:
a    3
b    5
c    8
dtype: int64

In [24]: s1+s2
Out[24]:
```

```
a    11
b    12
c    11
dtype: int64

In [25]: s3 = pd.Series([4, 2, 7], index=list('bcd'))

In [26]: s=s1+s3

In [27]: s
Out[27]:
a     NaN
b    11.0
c     5.0
d     NaN
dtype: float64

In [28]: s.fillna(0)
Out[28]:
a     0.0
b    11.0
c     5.0
d     0.0
dtype: float64
```

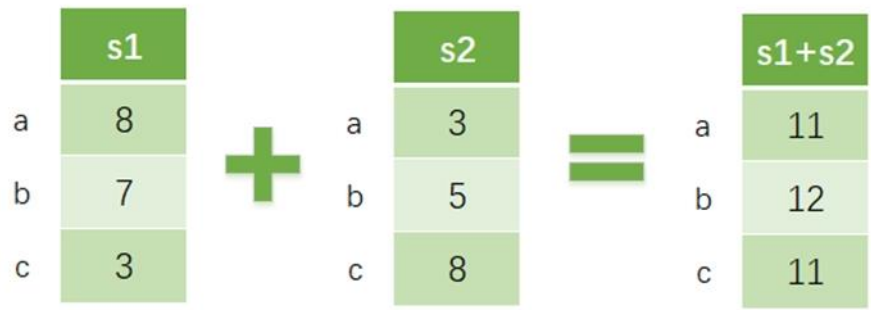

图 7-1 两个 Series 对象算术运算 1

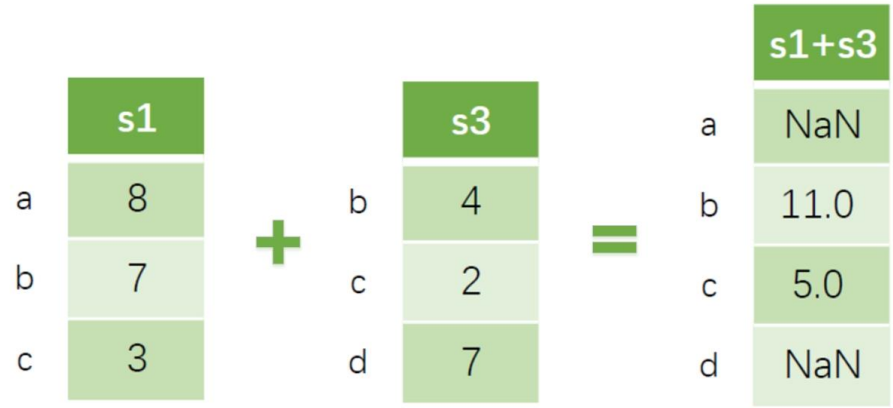

图 7-2 两个 Series 对象算术运算 2

2、两个 DataFrame 对象算术运算：

```
In [30]: data1 = {'apples': [3, 2, 0, 1],
    ...:          'oranges': [0, 1, 2, 3] }


In [31]: df1 = pd.DataFrame(data1,
index=['June','Robert','Lily','David'])


In [32]: df1
Out[32]:
        apples  oranges
June         3        0
Robert       2        1
Lily         0        2
David        1        3

In [33]: data2 = {'apples': [2, 2, 1],
    ...:           'oranges': [1, 1, 3],
    ...:           'bananas': [1, 2, 1] }

In [34]: df2 = pd.DataFrame(data2, index=['June','Robert','Lily'])


In [35]: df2
Out[35]:
        apples  oranges  bananas
```

```
June        2       1       1
Robert      2       1       2
Lily        1       3       1

In [36]: df = df1+df2

In [37]: df
Out[37]:
        apples  bananas  oranges
David      NaN      NaN      NaN
June       5.0      NaN      1.0
Lily       1.0      NaN      5.0
Robert     4.0      NaN      2.0

In [38]: df.fillna(0)
Out[38]:
        apples  bananas  oranges
David      0.0      0.0      0.0
June       5.0      0.0      1.0
Lily       1.0      0.0      5.0
Robert     4.0      0.0      2.0
```

	apples	oranges	bananas
June	2	1	1
Robert	2	1	2
Lily	1	3	1

	apples	oranges
June	3	0
Robert	2	1
Lily	0	2
David	1	3

	apples	bananas	oranges
David	NaN	NaN	NaN
June	5.0	NaN	2.0
Lily	1.0	NaN	5.0
Robert	4.0	NaN	2.0

图 7-3 两个 DataFrame 对象算术运算

3、Series 对象和 DataFrame 对象算术运算：

```
In [5]: data1 = { 'apples': [3, 2, 0, 1],
   ...:          'oranges': [0, 1, 2, 3] }


In [6]: df1 = pd.DataFrame(data1,
index=['June','Robert','Lily','David'])


In [7]: df1
Out[7]:
        apples  oranges
June         3        0
Robert       2        1
Lily         0        2
David        1        3


In [8]: s1 = pd.Series([1, 2, 3], index=['apples', 'oranges',
'bananas'])


In [9]: s1
Out[9]:
apples     1
oranges    2
bananas    3
dtype: int64


In [10]: df1+s1
Out[10]:
        apples  bananas  oranges
June         4      NaN        2
Robert       3      NaN        3
Lily         1      NaN        4
David        2      NaN        5
```

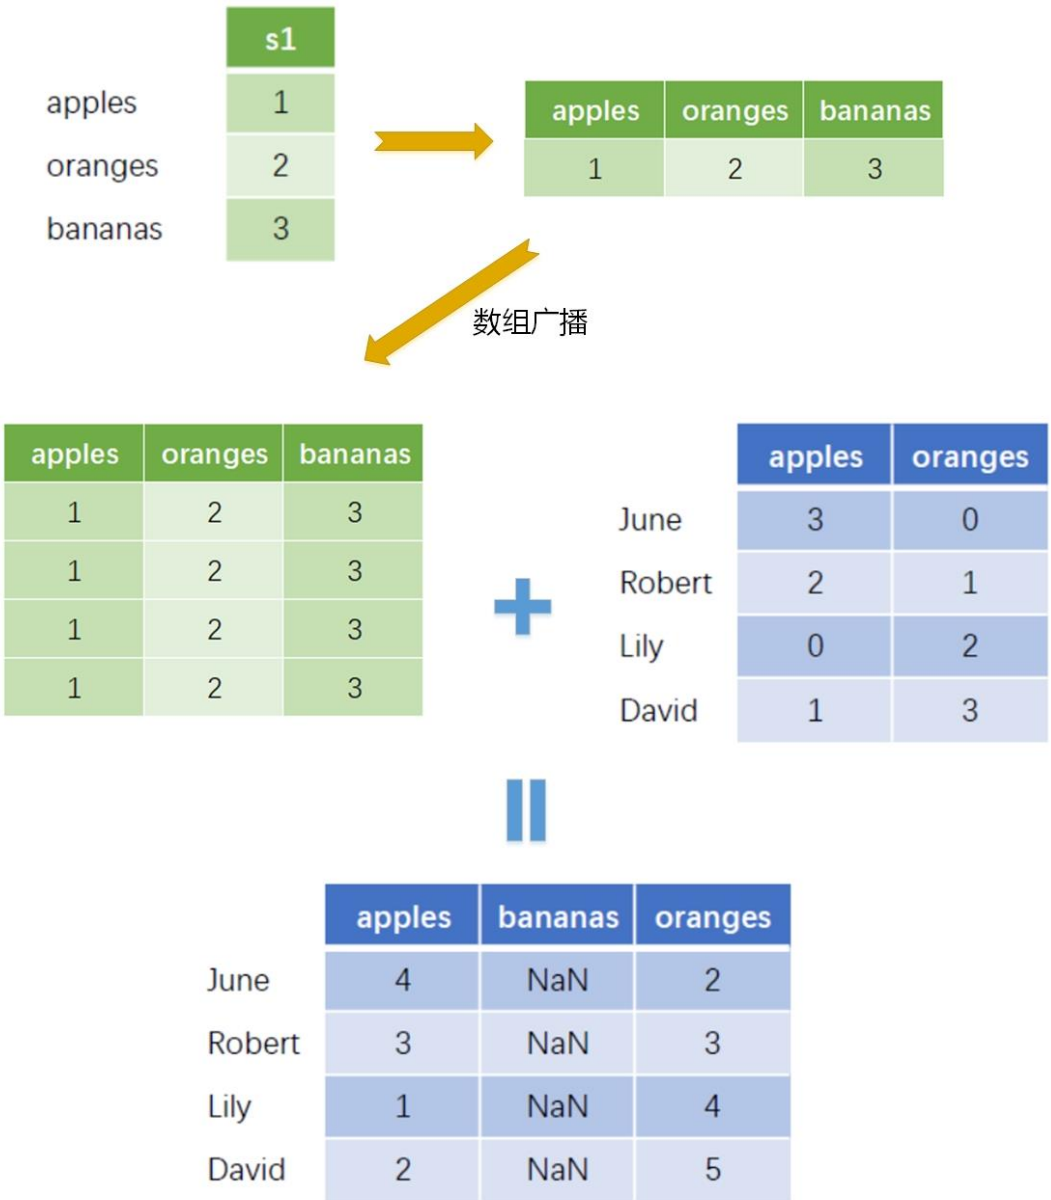

图 7-4 Series 对象和 DataFrame 对象算术运算

7.1.2 使用算术运方法

表 7-1　算术运算方法

方法	说明
add	加法（+）
sub	减法（-）
div	除法（/）
floordiv	整除（//）
mul	乘法（*）
pow	幂次方（**）

```
In [4]: s1+s2
Out[4]:
a    11
b    12
c    11
dtype: int64

In [5]: s1.add(s2)
Out[5]:
a    11
b    12
c    11
dtype: int64

In [6]: s1+s3
Out[6]:
a     NaN
b    11.0
c     5.0
d     NaN
dtype: float64

In [7]: s1.add(s3)
Out[7]:
```

```
a     NaN
b    11.0
c     5.0
d     NaN
dtype: float64

In [8]: s1.add(s3).fillna(0)
Out[8]:
a     0.0
b    11.0
c     5.0
d     0.0
dtype: float64

In [9]: df1+sf1
Out[9]:
       apples  bananas  oranges
June        4      NaN        2
Robert      3      NaN        3
Lily        1      NaN        4
David       2      NaN        5

In [10]: df1.add(sf1)
Out[10]:
       apples  bananas  oranges
June        4      NaN        2
Robert      3      NaN        3
Lily        1      NaN        4
David       2      NaN        5

In [11]: df1*df2
Out[11]:
       apples  bananas  oranges
David     NaN      NaN      NaN
June      6.0      NaN      0.0
Lily      0.0      NaN      6.0
Robert    4.0      NaN      1.0
```

```
In [12]: df1.mul(df2)
Out[12]:
        apples  bananas  oranges
David      NaN      NaN      NaN
June       6.0      NaN      0.0
Lily       0.0      NaN      6.0
Robert     4.0      NaN      1.0

In [13]: df1//df2
Out[13]:
        apples  bananas  oranges
David      NaN      NaN      NaN
June       1.0      NaN      0.0
Lily       0.0      NaN      0.0
Robert     1.0      NaN      1.0

In [14]: df1.floordiv(df2)
Out[14]:
        apples  bananas  oranges
David      NaN      NaN      NaN
June       1.0      NaN      0.0
Lily       0.0      NaN      0.0
Robert     1.0      NaN      1.0
```

7.2 描述性统计方法

Pandas 对象有一组常用的数学/统计方法：

- Series 中的各个元素汇总统计
- DataFrame 可以沿指定轴进行汇总统计

这些方法主要有 3 个参数：

1. axis 是沿指定轴的索引，默认为 0。DataFrame 对象 0 为行，1 为列；Series 对象只能为 0。
2. skipna 是排除缺失值，默认为 True。注意 count()方法没有该参

数。

3. level 如果是多级索引时，指定索引级别。

表 7-2　常用的统计方法

方法	说明
count()	计算非 NA 值的个数，注意没有 skipna 参数
sum()	求和
mean()	平均值
std()	标准差
min()、max()	计算最小值、最大值
prod()	所有值的乘积
cumsum()	计算累加值
cumprod()	计算累乘积值

```
In [7]: data = {'apples': [3, 2, 0, 1],
   ...:         'oranges': [0, 1, 2, 3],
   ...:         'bananas': [1, 2, 1, np.nan]}


In [8]: df = pd.DataFrame(data,
index=['June','Robert','Lily','David'])
In [9]: df
Out[9]:
        apples  oranges  bananas
June         3        0      1.0
Robert       2        1      2.0
Lily         0        2      1.0
David        1        3      NaN


In [10]: df.count()
Out[10]:
apples     4
oranges    4
bananas    3
dtype: int64
```

```
In [11]: df.count(1)
Out[11]:
June      3
Robert    3
Lily      3
David     2
dtype: int64

In [12]: df.sum()
Out[12]:
apples     6.0
oranges    6.0
bananas    4.0
dtype: float64

In [13]: df.sum(1)
Out[13]:
June      4.0
Robert    5.0
Lily      3.0
David     4.0
dtype: float64

In [14]: df.sum(skipna=False)
Out[14]:
apples     6.0
oranges    6.0
bananas    NaN
dtype: float64
```

7.3 函数应用

要将自定义函数或其他库中的函数应用于 Pandas 对象，有 3 个主要方法：

- apply(func) 方法可以应用于 Series 也可以应用于 DataFrame。
- applymap(func) 方法仅适用于 DataFrame。
- map(func) 方法仅适用于 Series。

7.3.1 函数应用 apply 方法

apply(func) 方法可以应用于 Series 也可以应用于 DataFrame。func 函数参数，如果是标量（单个元素），可以应用于 Series 和 DataFrame 每一个元素；如果参数是向量（列表、数组、其他 Series 对象）可以应用于 DataFrame 的行或列。

1、应用于 Series 和 DataFrame 对象每一个元素

```
In [3]: def func1(x): # x单个值（标量）
   ...:     return x*100
   ...:

In [4]: s = pd.Series([8, 7, 3], index=list('abc'))
   ...: s
Out[4]:
a    8
b    7
c    3
dtype: int64

In [5]: s.apply(func1)
Out[5]:
a    800
b    700
c    300
dtype: int64

In [6]: data = {'apples': [2, 2, 1],
```

```
    ...:         'oranges': [1, 1, 3],
    ...:         'bananas': [1, 2, 1] }
    ...: df = pd.DataFrame(data, index=['June','Robert','Lily'])
    ...: df
Out[6]:
       apples  oranges  bananas
June        2        1        1
Robert      2        1        2
Lily        1        3        1

In [7]: df.apply(func1)
Out[7]:
       apples  oranges  bananas
June      200      100      100
Robert    200      100      200
Lily      100      300      100
```

提示　自定义函数也可以使用Lambda表达式。例如：func1函数可以用lambda x:x*100表达式替代。

```
In [57]: s.apply(lambda x:x*100)
Out[57]:
a    800
b    700
c    300
dtype: int64

In [58]: df.apply(lambda x:x*100)
Out[58]:
       apples  oranges  bananas
June      200      100      100
Robert    200      100      200
Lily      100      300      100
```

2、应用于 DataFrame 对象的行或列

```
In [10]: s.apply(lambda x:x.max() - x.min())
---------------------------------------------------------------------
---------
AttributeError: 'int' object has no attribute 'max'

In [11]: df.apply(lambda x:x.max() - x.min())
Out[11]:
apples     1
oranges    2
bananas    1
dtype: int64

In [12]: df.apply(lambda x:x.max() - x.min(), axis=0)
Out[12]:
apples     1
oranges    2
bananas    1
dtype: int64

In [13]: df.apply(lambda x:x.max() - x.min(), axis=1)
Out[13]:
June      1
Robert    1
Lily      2
dtype: int64
```

提示　lambda x:x.max() - x.min()表达式用来计算向量，如max和min方法。

7.3.2 函数应用 applymap 方法

applymap(func) 方法仅适用于 DataFrame 对象每一个元素。

```
In [67]: df.applymap(lambda x:x*100)
Out[67]:
        apples  oranges  bananas
June       200      100      100
Robert     200      100      200
Lily       100      300      100
```

7.3.3 函数应用 map 方法

map(func) 方法仅适用于 Series 对象每一个元素。

```
In [70]: s.map(lambda x:x*100)
Out[70]:
a    800
b    700
c    300
dtype: int64
```

7.4 排序

Pandas 中对象（Series 和 DataFrame）可以通过标签或元素值进行排序。

7.4.1 通过标签排序

通过标签排序方法是 sort_index()，该方法主要的参数如下：

- axis：指定排序的轴，默认为 0。DataFrame 对象 0 为行，1 为列；Series 对象只能为 0。
- ascending：排序的顺序，默认为 True。True 为升序，False 为降序。

```
In [8]: s = pd.Series([8, 3, 7], index=list('bac'))


In [9]: s
Out[9]:
b    8
a    3
c    7
dtype: int64


In [10]: s.sort_index()
Out[10]:
a    3
b    8
c    7
dtype: int64


In [11]: s.sort_index(ascending=False)
Out[11]:
c    7
b    8
a    3
dtype: int64


In [12]: data = {'apples': [3, 2, 0, 1],
    ...:         'oranges': [0, 1, 2, 3],
    ...:         'bananas': [1, 2, 1, 0]}


In [13]: df = pd.DataFrame(data,
index=['June','Robert','Lily','David'])


In [14]: df
Out[14]:
        apples  oranges  bananas
June         3        0        1
Robert       2        1        2
Lily         0        2        1
David        1        3        0
```

```
In [15]: df.sort_index()
Out[15]:
       apples  oranges  bananas
David       1        3        0
June        3        0        1
Lily        0        2        1
Robert      2        1        2

In [16]: df.sort_index(axis=1)
Out[16]:
       apples  bananas  oranges
June        3        1        0
Robert      2        2        1
Lily        0        1        2
David       1        0        3

In [17]: df.sort_index(ascending=False)
Out[17]:
       apples  oranges  bananas
Robert      2        1        2
Lily        0        2        1
June        3        0        1
David       1        3        0

In [18]: df.sort index(axis=1, ascending=False)
Out[18]:
       oranges  bananas  apples
June         0        1       3
Robert       1        2       2
Lily         2        1       0
David        3        0       1
```

7.4.2 通过元素值排序

元素值排序方法是 sort_values()，该方法主要的参数如下：

- by：指定排序的行标签或列标签，可以是字符串或字符串列表。注意 Series 对象没有该参数。
- axis：指定排序的轴，默认为 0。DataFrame 对象 0 为行，1 为列；Series 对象只能为 0。
- ascending：排序的顺序，默认为 True。True 为升序，False 为降序。

```
In [67]: s.sort_values()
Out[67]:
a    3
c    7
b    8
dtype: int64

In [68]: s.sort_values(ascending=False)
Out[68]:
b    8
c    7
a    3
dtype: int64

In [71]: df.sort_values('apples')
Out[71]:
       apples  oranges  bananas
Lily        0        2        1
David       1        3        0
Robert      2        1        2
June        3        0        1

In [72]: df.sort_values(by='apples')
Out[72]:
       apples  oranges  bananas
Lily        0        2        1
```

```
David       1       3       0
Robert      2       1       2
June        3       0       1

In [74]: df.sort_values(['bananas','oranges'])
Out[74]:
       apples  oranges  bananas
David       1       3       0
June        3       0       1
Lily        0       2       1
Robert      2       1       2

In [75]: df.sort_values('Lily',axis=1)
Out[75]:
       apples  bananas  oranges
June        3       1       0
Robert      2       2       1
Lily        0       1       2
David       1       0       3
```

7.5 课后练习

1、如何将 Series 中每个元素的第一个字符转换为大写？

参考答案：

```
import pandas as pd
ser = pd.Series(['how', 'to', 'kick', 'ass?'])
ser.map(lambda x: x[0].upper() + x[1:])
```

2、如何计算 Series 中每个单词的字符数？

参考答案：

```
import pandas as pd
ser = pd.Series(['how', 'to', 'kick', 'ass?'])
ser.map(lambda x: len(x))
```

3、计算 Series 数据对象的平均值和标准差？

参考答案：

```
import pandas as pd
s = pd.Series(data = [1,2,3,4,5,6,7,8,9,5,3])
print("原始数据：")
print(s)
print("数据平均值：")
print(s.mean())
print("数据标准偏差：")
print(s.std())
```

4、编写一个 pandas 程序实现两个 Series 对象的加、减、乘、除计算。

参考答案：

```
import pandas as pd
ds1 = pd.Series([2, 4, 6, 8, 10])
ds2 = pd.Series([1, 3, 5, 7, 9])
print("两个Series对象相加：")
ds = ds1 + ds2
print(ds)

print("两个Series对象相减：")
ds = ds1 - ds2
print(ds)

print("两个Series对象相乘：")
ds = ds1 * ds2
print(ds)
```

```
print("两个Series对象相除：")
ds = ds1 / ds2
print(ds)
```

5、编写一个 pandas 程序实现两个 Series 对象的比较计算。

参考答案：

```
import pandas as pd
ds1 = pd.Series([2, 4, 6, 8, 10])
ds2 = pd.Series([1, 3, 5, 7, 10])
print("Series对象1:")
print(ds1)
print("Series对象2:")
print(ds2)
print("比较Series对象:")
print("相等:")
print(ds1 == ds2)
print("大于:")
print(ds1 > ds2)
print("小于:")
print(ds1 < ds2)
```

6、编写一个 pandas 程序计算 DataFrame 对象某一列的平均值。

参考答案：

```
import pandas as pd
exam_data  = {'name': ['Anastasia', 'Dima', 'Katherine', 'James',
'Emily', 'Michael', 'Matthew', 'Laura', 'Kevin', 'Jonas'],
        'score': [12.5, 9, 16.5, np.nan, 9, 20, 14.5, np.nan, 8, 19],
        'attempts': [1, 3, 2, 3, 2, 3, 1, 1, 2, 1],
        'qualify': ['yes', 'no', 'yes', 'no', 'no', 'yes', 'yes',
'no', 'no', 'yes']}
labels = ['a', 'b', 'c', 'd', 'e', 'f', 'g', 'h', 'i', 'j']


df = pd.DataFrame(exam_data , index=labels)
```

```
print(df['score'].mean())
```

7、在第 6 题基础上对 DataFrame 对象首先按 name 列降序排列，而且按 score 列升序排列。

参考答案：

```
df.sort_values(by=['name', 'score'], ascending=[False, True])
```

8、在第 6 题基础上对 DataFrame 对象替换 qualify 列 yes 和 no 为 True 和 False。

参考答案：

```
df['qualify'] = df['qualify'].map({'yes': True, 'no': False})
```

9、读取 CSV 数据（煤矿生成历史数据 2013.csv）到 DataFrame 对象，并计算“产能”列的总和、平均值、最大值、最小值。

参考答案：

```
import pandas as pd
df = pd.read_csv(file_dir+'煤矿生成历史数据2013.csv',engine='python')
print("Sum: ",df["产能"].sum())
print("Mean: ",df["产能"].mean())
print("Maximum: ",df["产能"].max())
print("Minimum: ",df["产能"].min())
```

10、读取 CSV 数据（煤矿生成历史数据 2013.csv）到 DataFrame 对象，并示并查找“矿山名”以“P”开通的数据。

参考答案：

```
import pandas as pd
```

```
df = pd.read_csv(file_dir+'煤矿生成历史数据2013.csv', engine='python')
df[df["矿山名"].map(lambda x: x.startswith('P'))]
```

11、读取 Excel 文件数据（雇员.xlsx）到 DataFrame 对象，并根据多个给定列进行排序。

参考答案:

```
import pandas as pd
df = pd.read_excel(file_dir+'雇员.xlsx', index_col=0)
result = df.sort_values(by=['first_name','last_name'],ascending=[0,1])
print(result)
```

12、读取 Excel 文件数据(雇员.xlsx)到 DataFrame 对象,并按 hire_date 列对记录进行排序。

参考答案:

```
import pandas as pd
df = pd.read_excel(file_dir+'雇员.xlsx', index_col=0)
result = df.sort_values('hire_date')
print(result)
```

第8章 项目实战：搜狐证券股票数据分析

8.1 获取贵州茅台股票历史数据

http://q.stock.sohu.com/cn/600519/lshq.shtml

1、通过网络爬虫，爬取数据。

2、通过 pandas.read_html()方法。

3、通过 pandas.read_clipboard()方法。

8.2 获得特定时间段股票数据

query 方法

布尔数组

8.3 查询时间段内最大【成交量】日期

max()取最大值。

idmax()取最大值索引。

8.4 将股票信息中【日期】字符串转换为日期类型

8.5 请按照【成交金额】排序

8.6 绘制股票【成交量】折线图

Matplotlib 数据可视化库